




AZENTA 安升达
LIFE SCIENCES

常用生物信息学格式介绍

xi.zhu

2024年/8月

01	fasta格式
02	fastq格式
03	bed格式
04	sam/bam格式
05	vcf格式
06	gff3格式
07	常用软件

使用软件安装方式



samtools 安装方式1 (编译安装)

- wget <https://github.com/samtools/samtools/releases/download/1.15.1/samtools-1.15.1.tar.bz2>
- tar -xjf samtools-1.15.1.tar.bz2
- cd samtools-1.15.1
- ./configure --prefix=/usr/localmakesudo
- make install

samtools 安装方式2 (conda安装)

- conda install -c bioconda samtools

使用软件安装方式



bedtools 安装方式1 (编译安装)

- git clone <https://github.com/arq5x/bedtools2.git>
- cd bedtools2
- make
- sudo make install

bedtools 安装方式2 (conda安装)

- conda install -c bioconda bedtools

使用软件安装方式



seqtk 安装方式1 (编译安装)

- `git clone https://github.com/lh3/seqtk.git`
- `cd seqtk`
- `make`
- `sudo cp seqtk /usr/local/bin/`

seqtk 安装方式2 (conda安装)

- `conda install -c bioconda seqtk`

fasta格式

记录氨基酸、核酸序列信息

01

fasta格式

- fasta格式是最基本的表示序列信息（记录**核酸序列**或者**氨基酸序列**）的格式。
- fasta格式的文件通常后缀名为.fasta 或者.fa， 文本文件，可用文本编辑器（记事本等）直接打开。
- fasta格式文件（可以包含多条序列）中的一条序列的通常表示方法如下：

>**A00202:1550:HCG3GDSXC:3:1101:16007:5478** 1:N:0:AGGCAGAA+GCGATCTA

ATTACAGGATGCAGATCAGCAGCTAGAATTTTTAAATGAAATCCAGCAATCCATTGGAAAATCTGCGGAATTAATCTAT
TTACATGCAGTTCTTGCCATGAAGAAAAATAACGACAAGAAGAAGTTATTAATTTGTTAAATGATGTCCT

fasta格式

特点:

>A00202:1550:HCG3GDSXC:3:1101:16007:5478 1:N:0:AGGCAGAA+GCGATCTA

- 描述部分：只能写一行
- 描述部分：均以大于号 (>) 作为开头
- 描述部分：以空格或tab为分隔，通常前面部分为ID (红色)，后面部分为其他描述 (黑色)

ATTACAGGATGCAGATCAGCAGCTAGAATTTTTAAATGAAATCCAGCAATCCATTGGAAAATCTGCGGAATTAATCTATTTACATGCAGTTCTTG
CCATGAAGAAAAATAAACGACAAGAAGAAGTTATTAATTTGTTAAATGATGTCCT

- 序列部分：可以一行，也可以分多行显示 (一般60-80bp)
- 序列部分：只能包含标准的碱基或氨基酸

fastq格式

不仅记录序列，还记录质量值

02

fastq格式

第一行序列名称解释（可了解）

@A00202:1550:HCG3GDSXC:3:1101:16007:5478 1:N:0:AGGCAGAA+GCGATCTA

A00202	仪器编号
1550	测序运行编号
HCG3GDSXC	测序批次唯一标识符
3	流动池编号
1101	流动槽编号
16007	X 坐标，表示簇在图像上的位置
5478	Y 坐标，表示簇在图像上的位置
1	读数编号，一般为1、2
N	过滤标记
0	控制编号，通常用于内部用途
AGGCAGAA+GCGATCTA	Index 序列

fastq格式

查看压缩fastq的N种方式

```
less sample.R1.fastq.gz | head -n 8
```

```
zcat sample.R1.fastq.gz | head -n 8
```

查看所有序列

```
less sample.R1.fastq.gz | awk 'NR%4==2' | less
```

计算序列数

```
less sample.R1.fastq.gz | awk 'NR%4==2' | wc -l
```

```
less sample.R1.fastq.gz | grep -c '^@'
```

fastq 文件格式转换 (可了解)

```
seqtk seq -a sample.R1.fastq.gz > sample.R1.fasta
```

根据ID提取序列 (可了解)

```
less sample.R1.fastq.gz | awk 'NR%4==1' | awk '{print substr($1, 2)}' | shuf -n 10 > id.list
```

```
seqtk subseq sample.R1.fastq.gz id.list > extracted.R1.fastq
```

```
seqtk subseq sample.R2.fastq.gz id.list > extracted.R2.fastq
```

bed格式

记录位置信息

03

bed格式

特点:

- 1. bed文件是记录序列位置的一种方式;
- 2. 通常以文本形式保存;
- 3. 以制表符 (TAB) 分隔, 包含至少三列 (染色体ID, 起始位置, 终止位置) 。

示例

```
chr1 12080 12251
chr1 12595 12802
chr1 13163 13658
chr1 14620 15015
chr1 15795 15914
chr1 16743 17098
```



sam/bam格式

记录序列比对结果

04

sam/bam格式



sam文件是保存**比对信息**的文件格式；bam文件是sam格式的压缩，更便于传输和查看。
通常用于记录测序数据比对到基因组的位置信息等，由比对软件（例如bowtie, hisat2, bwa, star等）直接生成。

特点：

- (1) sam文件包含比对质量，比对位置，序列等信息；
- (2) sam文件通常非常大，可以达到几百G；
- (3) sam文件是**文本**格式，但由于较大，一般无需用文本编辑器打开，相关软件可以直接读取；
- (4) bam文件是sam文件的**压缩**格式，非文本格式，节省存储空间。

可视化区别	区别	linux
sam	文本	导入IGV; 或使用 less 、 cat 等常规查看命令
bam	二进制压缩	导入IGV; 或使用相关软件才可查看，例如 samtools view

sam/bam格式

文件示例

- 1. SAM文件包含head注释部分和正文部分
- 2. head部分以@开头，记录了每条染色体的长度信息，比对命令等信息
- 3. 正文部分是以制表符（TAB）为分隔符的表格，记录比对结果

```
@HD      VN:1.4      SO:coordinate
@SQ      SN:chr1    LN:248956422
@RG      ID:sample  SM:sample  PL:illumina
@PG      ID:BWA     PN:BWA     VN:0.7.12-r1039      CL:bwa mem -t 4 ref.fasta sample.fastq
A00599:561:H7KCMDSXC:1:1419:19714:12399      163      chr1      17301      40      150M
=      17376      225      CCCCCAGCATCACATGGGTCTTTGTTACAGCACCAGCCAGGGGGTCCAGGAAGACATACTT
CTTCTACCTACAGAGGCGACATGGGGGTCAGGCAAGCTGACACCCGCTGTCCTGAGCCCATGTTTCCTCTCCCACATCATCAGGGGCACA
FFFFF:FFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFF
FFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFF
```


sam/bam格式

head注释部分

@HD VN:1.6 SO:coordinate	记录了BAM文件的基本信息。 VN： SAM格式的版本号； SO： 结果排序方式（coordinate：染色体坐标排序）
@SQ SN:chr1 LN:248956422	每个染色体的长度信息。 SN： 染色体的名称； LN： 染色体的长度
@RG ID:sample SM:sample PL:illumina	测序样本的相关信息。 ID： 样本的唯一标识符； SM： 样本名； PL： 测序平台
@PG ID:BWA PN:BWA VN:0.7.12-r1039 CL:bwa mem -t 4 ref.fasta sample.fastq	关于比对工具的信息。 ID： 程序的唯一标识符； PN： 程序名， VN： 版本； CL： 程序运行命令行

sam/bam格式

正文比对部分

列	示例	名称	描述信息
1	A00599:561:H7KCMDSXC:1:1419:19714:12399	QNAME	序列名称
2	163	FLAG	比对flag编码
3	chr1	RNAME	比对到的染色体编号
4	17301	POS	比对到的起始位置
5	40	MAPQ	比对质量
6	150M	CIGAR	比对详情 (CIGAR)
7	=	RNEXT	PairEnd的另一端序列比对的染色体
8	17376	PNEXT	PairEnd的另一端序列比对的起始位置
9	225	TLEN	插入片段大小
10	CCCCCAG*****CAGGGGCACA	SEQ	序列碱基
11	FFFFFF:F*****FFFFFFFFFFFF	QUAL	碱基质量值

sam/bam格式

其他拓展:

sam文件详细定义见: <http://samtools.github.io/hts-specs/SAMv1.pdf>

比对结果flag值详细解释: <https://broadinstitute.github.io/picard/explain-flags.html>

比对结果CIGAR值详细解释: <https://genome.sph.umich.edu/wiki/SAM>

使用生信软件samtools实现sam和bam的互相转换:

#sam转bam:

```
samtools view -bS sample.sam > sample.bam
```

#bam转sam:

```
samtools view -h sample.bam > sample.sam
```

vcf格式

记录突变信息

05

vcf格式

vcf (Variant Call Format) 是一种用于描述基因组中**变异信息**的标准文件格式。

特点:

- (1) 包含Header与Body两部分;
- (2) Header部分: 以#标记为开头;
- (3) Header部分: 描述本文件内**各标签的含义**, 文件来源及其命令, 基因组长度, Body部分对应表头等信息;
- (4) Header部分: 一般由变异分析软件自动添加, 无需手动添加;
- (5) Body部分: 变异信息, 可描述SNP、InDel、SV等变异信息。

```
##fileformat=VCFv4.2
##FORMAT=<ID=AD,Number=R,Type=Integer,Description="Allelic depths for the ref and alt alleles in the order listed">
##FORMAT=<ID=DP,Number=1,Type=Integer,Description="Read depth">
##FORMAT=<ID=GQ,Number=1,Type=Integer,Description="Genotype quality">
##FORMAT=<ID=GT,Number=1,Type=String,Description="Genotype">
##INFO=<ID=DB,Number=0,Type=Flag,Description="dbSNP membership">
##INFO=<ID=DP,Number=1,Type=Integer,Description="Combined depth across samples">
##SentieonCommandLine.Haplotyper=<ID=Haplotyper,Version="202010.02",CommandLine="/EMCDisk1/home/software/sentieon/libexec/driver -r hg38.fa -t 24 -i sample.final.bam -q sample.recal_data.table --algo Haplotyper sample.final.vcf.gz">
##contig=<ID=chr1,length=248956422,assembly=hg38>
##reference=hg38.fa
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT sample
chr1 12807 . C T 95.65 . AC=1;AF=0.5;AN=2;BaseQRankSum=-0.524;ClippingRankSum=-0.000;DP=5;ExcessHet=3.0103;FS=0.000;MLEAC=1;MLEAF=0.5;MQ=25.22;MQRankSum=-1.282;QD=19.13;ReadPosRankSum=1.282;SOR=1.981 GT:AD:DP:GQ:PL 0/1:1,4:5:17:103,0,17
chr1 13418 . G A 30.64 . AC=1;AF=0.5;AN=2;BaseQRankSum=2.808;ClippingRankSum=0.000;DP=35;ExcessHet=3.0103;FS=13.074;MLEAC=1;MLEAF=0.5;MQ=30.80;MQRankSum=-1.533;QD=0.88;ReadPosRankSum=-1.256;SOR=3.605 GT:AD:DP:GQ:PL 0/1:30,5:35:38:38,0,794
chr1 13813 . T G 56.64 . AC=1;AF=0.5;AN=2;BaseQRankSum=-2.575;ClippingRankSum=0.000;DP=25;ExcessHet=3.0103;FS=5.618;MLEAC=1;MLEAF=0.5;MQ=26.77;MQRankSum=-1.182;QD=2.27;ReadPosRankSum=1.118;SOR=2.546 GT:AD:DP:GQ:PL 0/1:20,5:25:64:64,0,880
```


vcf格式

```
#CHROM POS ID REF ALT QUAL FILTER INFO FORMAT sample
chr1 12807 . C T 95.65 . AC=1;AF=0.5;AN=2;BaseQRankSum=-0.524;ClippingRankSum=-0.000;DP=5;ExcessHet=3.0103;FS=0.000;MLEAC=1;MLEAF=0.5;
MQ=25.22;MQRankSum=-1.282;QD=19.13;ReadPosRankSum=1.282;SOR=1.981 GT:AD:DP:GQ:PL 0/1:1,4:5:17:103,0,17
chr1 13418 . G A 30.64 . AC=1;AF=0.5;AN=2;BaseQRankSum=2.808;ClippingRankSum=0.000;DP=35;ExcessHet=3.0103;FS=13.074;MLEAC=1;MLEAF=0.5;
MQ=30.80;MQRankSum=-1.533;QD=0.88;ReadPosRankSum=-1.256;SOR=3.605 GT:AD:DP:GQ:PL 0/1:30,5:35:38:38,0,794
chr1 13813 . T G 56.64 . AC=1;AF=0.5;AN=2;BaseQRankSum=-2.575;ClippingRankSum=0.000;DP=25;ExcessHet=3.0103;FS=5.618;MLEAC=1;MLEAF=0.5;
MQ=26.77;MQRankSum=-1.182;QD=2.27;ReadPosRankSum=1.118;SOR=2.546 GT:AD:DP:GQ:PL 0/1:20,5:25:64:64,0,880
```

名称	示例	描述
CHROM	chr1	染色体编号
POS	13813	变异位置
ID	.	变异名称
REF	T	参考基因组碱基
ALT	G	突变碱基
QUAL	56.64	变异质量
FILTER	.	过滤标签
INFO	AC=1.....	变异注释信息
FORMAT	GT:AD:DP:GQ:PL	样本各字段对应的格式
sample	0/1:20,5:25:64:64,0,880	各样本字段内容与FORMAT对应

gff3格式

记录基因注释信息

06

vcf格式

gff3 (General Feature Format version 3) 是描述**相关特征** (包括基因、转录本、外显子、UTR等等) 在基因组序列的位置等信息的文件;

定义了每个特征所在的染色体编号、起始位置、终止位置、所在的正负链信息、名称等信息。

特点:

- (1) 一般只记录特征的位置信息, 不包含序列信息;
- (2) 每个gff3文件都对应了一个版本的基因组序列;
- (3) 染色体名称必须与基因组序列ID**完全一致**;

vcf格式

```
##gff-version 3
#!gff-spec-version 1.21
#!processor NCBI annotwriter
#染色体ID 数据库名称 特征类型 起始位置 终止位置 打分值 正负链 阅读框 GFF属性
1 araport11 gene 3631 5899 . + . ID=AT1G01010;Name=NAC001
1 araport11 mRNA 3631 5899 . + . ID=AT1G01010.1;Parent=AT1G01010
1 araport11 five_prime_UTR 3631 3759 . + . Parent=AT1G01010.1
1 araport11 exon 3631 3913 . + . Parent=AT1G01010.1
1 araport11 CDS 3760 3913 . + 0 ID=CDS:AT1G01010.1;Parent=AT1G01010.1;protein_id=AT1G01010.1
1 araport11 exon 3996 4276 . + . Parent=transcript:AT1G01010.1
1 araport11 CDS 3996 4276 . + 2 ID=CDS:AT1G01010.1;Parent=transcript:AT1G01010.1
1 araport11 exon 4486 4605 . + . Parent=transcript:AT1G01010.1
1 araport11 CDS 4486 4605 . + 0 ID=CDS:AT1G01010.1;Parent=transcript:AT1G01010.1
1 araport11 exon 4706 5095 . + . Parent=transcript:AT1G01010.1
1 araport11 CDS 4706 5095 . + 0 ID=CDS:AT1G01010.1;Parent=transcript:AT1G01010.1
1 araport11 exon 5174 5326 . + . Parent=transcript:AT1G01010.1
1 araport11 CDS 5174 5326 . + 0 ID=CDS:AT1G01010.1;Parent=transcript:AT1G01010.1
1 araport11 CDS 5439 5630 . + 0 ID=CDS:AT1G01010.1;Parent=transcript:AT1G01010.1
1 araport11 exon 5439 5899 . + . Parent=transcript:AT1G01010.1;
1 araport11 three_prime_UTR 5631 5899 . + . Parent=transcript:AT1G01010.1
```



常用软件

07

bedtools

bedtools 是一个用于基因组分析的强大的命令行工具集，它提供了许多用于处理基因组数据的功能和实用程序。是生物信息学中常用的工具之一。

sort/merge 排序、合并



```
bedtools sort -i A.bed
```


```
bedtools merge -i A.bed
```

```
bedtools merge -i A.bed -d 10
```

bedtools

bedtools 是一个用于基因组分析的强大的命令行工具集，它提供了许多用于处理基因组数据的功能和实用程序。是生物信息学中常用的工具之一。

intersect 区域取交集



```
bedtools intersect -a A.bed -b B.bed
```


```
bedtools intersect -a A.bed -b B.bed -wa
```

```
bedtools intersect -a A.bed -b B.bed -v
```

bedtools

bedtools 是一个用于基因组分析的强大的命令行工具集，它提供了许多用于处理基因组数据的功能和实用程序。是生物信息学中常用的工具之一。

getfasta 提取目标位置的序列



```
bedtools getfasta -fi input.fa -bed target.bed -fo target.fa
```


bedtools

bedtools 是一个用于基因组分析的强大的命令行工具集，它提供了许多用于处理基因组数据的功能和实用程序。是生物信息学中常用的工具之一。

maskfasta 标记目标序列

FASTA ACAGACTGGTATGAAGGTGGCCACAATTCAGAAAGAAAAAGAAGAGC

BED 

FASTA' ACANNNNGGTANNNNNNGGCCACANNNNNNAAGAANNNNNAGAGC

#常规使用

```
bedtools maskfasta -fi input.fa -bed target.bed -fo output.fa
```

转小写

```
bedtools maskfasta -fi input.fa -bed target.bed -fo output.fa -soft
```

使用其他碱基代替

```
bedtools maskfasta -fi input.fa -bed target.bed -fo output.fa -mc X
```

samtools



samtools 是一款用于操作和处理高通量测序数据的软件工具集。它主要用于处理比对结果sam和bam文件。

查看 bam 文件内容

```
samtools view sample.bam
```

E200019089L1C026R02203224356	163	NC_086019.1	22	19	33M1I116M	=	96
E200019089L1C034R01504963516	163	NC_086019.1	88	0	119M	=	345 376
E200019089L1C026R02203224356	83	NC_086019.1	96	19	148M	=	22 -222
E200019089L1C023R02503476856	97	NC_086019.1	340	0	81M1D69M		NC_086037.1
E200019089L1C033R03504258341	97	NC_086019.1	341	0	80M1D70M		NC_086037.1
E200019089L1C034R01504963516	83	NC_086019.1	345	0	119M	=	88 -376
E200019089L1C011R03104572221	99	NC_086019.1	372	0	150M	=	540 317
E200019089L1C032R03200491007	99	NC_086019.1	373	0	149M	=	540 315
E200019089L1C019R03202836298	65	NC_086019.1	380	0	149M	NC_086026.1	1311
E200019089L1C017R03300396684	163	NC_086019.1	522	0	150M	=	537 165

```
$ less sample.final.bam
"sample.final.bam" may be a binary file.  See it anyway?
```

bam无法使用less、cat等查看文本的方式查看，不然就...

```
^_<8B>^H^D^@^@^@^@<FF>^F^@BC^B^@-^G<ED>} \<D7><D5><84>^]<8F>^
<F0>0<E2><BF>-<D9><CA>VZ(<A1><B4><U+052C>ih<CA>^<BA>b<9A>B<8B><A1>,<A
<A1>s<E4><EA> <80><F9>G<96>j<EB>+ml<CA><DA><DA>/ho^N<87><A3><A
^Q!
^B0
```


samtools

sort 排序

```
samtools sort sample.bam -o sample_sorted.bam
```

index 建索引, 可以快速访问bam中的特定位置

```
samtools index sample_sorted.bam
```

merge 合并

```
samtools merge merged.bam 1.bam 2.bam 3.bam
```

使用 samtools 计算比对深度

计算最高深度10000

```
samtools depth -d 10000 sample.bam
```

计算多个样本的深度

```
samtools depth 1.bam 2.bam 3.bam
```

计算指定区域的深度

```
samtools depth -r chr1:1000000-2000000 sample.bam
```

计算bed区域的深度


```
samtools depth -b target.bed -d 100000 sample.bam
```

samtools

samtools flagstat sample.bam # 比对文件常规质控查看

示例	解释
791181822 + 0 in total (QC-passed reads + QC-failed reads)	比对文件中总序列数
4645484 + 0 secondary	次要比对序列数 (secondary alignment) 。次要比对是指一个读段除了主比对 (primary alignment) 外，另一个可能的位置。
0 + 0 supplementary	没有补充比对 (supplementary alignment) 。补充比对是指读段的部分比对位置，常用于处理分裂读段 (split reads) 。
40872334 + 0 duplicates	重复DUP序列数
786785910 + 0 mapped (99.44% : N/A)	比对上的序列
786536338 + 0 paired in sequencing	成对序列数
393268169 + 0 read1	R1序列数
393268169 + 0 read2	R2序列数
754732618 + 0 properly paired (95.96% : N/A)	正确配对的序列数
780678310 + 0 with itself and mate mapped	序列及其配对序列能比对的数目
1462116 + 0 singletons (0.19% : N/A)	单端比对序列数
21799552 + 0 with mate mapped to a different chr	比对到不同的染色体序列数
14197083 + 0 with mate mapped to a different chr (mapQ>=5)	比对到不同染色体，且比对质量得分>=5的序列数

Thank you!



AZENTA 安升达
LIFE SCIENCES