




AZENTA 安升达
LIFE SCIENCES

CRISPR 文库质检数据分析

目录



输入文件准备及库文件下载	04
数据质控	07
gRNA 序列提取与统计	12
gRNA 比对与数目统计	15
测序深度、覆盖度及均一性评估	19
常见问题	23

使用软件及安装

质控软件：fastqc

```
conda install -c bioconda fastqc
```

```
sudo apt-get install fastqc
```

提取sgRNA序列软件：cutadapt

```
conda install -c bioconda cutadapt
```

```
pip install cutadapt
```

比对软件：mageck count

```
conda install -c bioconda mageck
```

```
pip install mageck
```


分析流程



模块导入 → 处理库文件 → 提取sgRNA → 比对 → 统计

↓
Library

↓
Fastq文件

输入文件准备及库文件下载

01

输入内容准备



1.sgRNA上下游、长度

1. 基本信息	
*gRNA长度:	20,21
*sgRNA上下游:	CACC-GTTTT
*物种:	hsa
gRNA库信息	自提供文库（ 请填写gRNA 长度、sgRNA上下游序列并填写库文件信息单）
*分析类型	1.sgRNA文库质检

2.原始数据

双端测序数据，序列数据由两个 FASTQ 文件构成，分别保存每一端测序的读段。

FASTQ 格式文件中每条 read 由四行组成：

@GWZHISEQ01:289:C3Y96ACXX:6:1101:1704:2425 1:N:0:GGCTAC
GCTCTTTGCCCTTCTCGTCGAAAATTGTCTCCTCATTCGAAACTTCTCTG
+
AFFFFFFKKFFFFF

常用库文件下载

库文件下载方式

下载地址：<https://www.addgene.org/crispr/libraries/>

gRNA

序列

基因

gRNA_1,CAAGAGAAAGACCACGAGCA,A1BG
gRNA_2,GCTCAGCTGGGTCCATCCTG,A1BG
gRNA_3,ACTGGCGCCATCGAGAGCCA,A1BG
gRNA_4,GTCTGAGCTGATTCTGAGCGA,A1BG
gRNA_5,TGCGCTGGACCAGTGCGCGG,A1CF
gRNA_6,GGTGCAGCATCCCAACCAGG,A1CF
gRNA_7,ATGACTCTCATACTCCACGA,A1CF
gRNA_8,AGTTATGTTAGGTATACCCG,A1CF
gRNA_9,ATAGGGCCAACATTCTCTAGA,A2ML1
gRNA_10,CAAACAAACCTTCTGAACGG,A2ML1
gRNA_11,AAGGTTCTAATTCAGAGGCA,A2ML1
gRNA_12,TGGAACGAAGTTGCTATCCA,A2ML1
gRNA_13,GAAGAACCAGACTTGGATGA,A2M
gRNA_14,AACAGCCACACTCACAGCGA,A2M
gRNA_15,TAAGAAGCGGACCACAGTGA,A2M
gRNA_16,AACTCACCAACTCATTTCAGG,A2M
gRNA_17,CCTGGAAGAGAATCTTCTGG,A3GALT2
gRNA_18,AGCTGGGACATTGTGGCCGA,A3GALT2

Name	ID	Library Type	Species	PI	Lentiviral Generation	gRNAs per gene	Total gRNAs
Dual sgRNA CRISPRa Libraries	187249 – 187251 1000000193	Activation	Human	Weissman	3rd	6	Varies
Dual sgRNA CRISPRi Libraries	187246 – 187248 1000000192	Inhibition	Human	Weissman	3rd	6	Varies
Activity-optimized genome-wide library	Discontinued	Knockout	Human	Sabatini and Lander	3rd	10	178,896
Activity-optimized genome-wide library	1000000100	Knockout	Human	Sabatini and Lander	3rd	10	187,535
Adamson DNA Repair CRISPRi Libraries	177663, 177664, 177670	Inhibition	Human	Adamson	3rd	~3	366 or 1,573
BARBEKO sgRNA Library	174163	Knockout, Base Editing	Human	Wei	3rd	3	53,502
Bassik Human CRISPR Knockout Library	101926 – 101934	Knockout	Human	Bassik	3rd	10	Varies
Berger Lab Human Paralog Knockout Library (pgPEN)	171172	Knockout	Human	Berger	3rd	8-16	33,170

数据质控

02

数据质控

质控软件: fastqc

```
fastqc -o 01.QC 00.Raw_data/${sam}.fq.gz 00.Raw_data/${sam}.fq.gz
```

参数:

-o --outdir: 输出路径

查看运行结果

```
$ ll -h
```

```
Sample1.R1_fastqc.html  
Sample1.R1_fastqc.zip  
Sample1.R2_fastqc.html  
Sample1.R2_fastqc.zip
```

```
$ unzip Sample1.R1_fastqc.zip
```

质控软件：fastqc

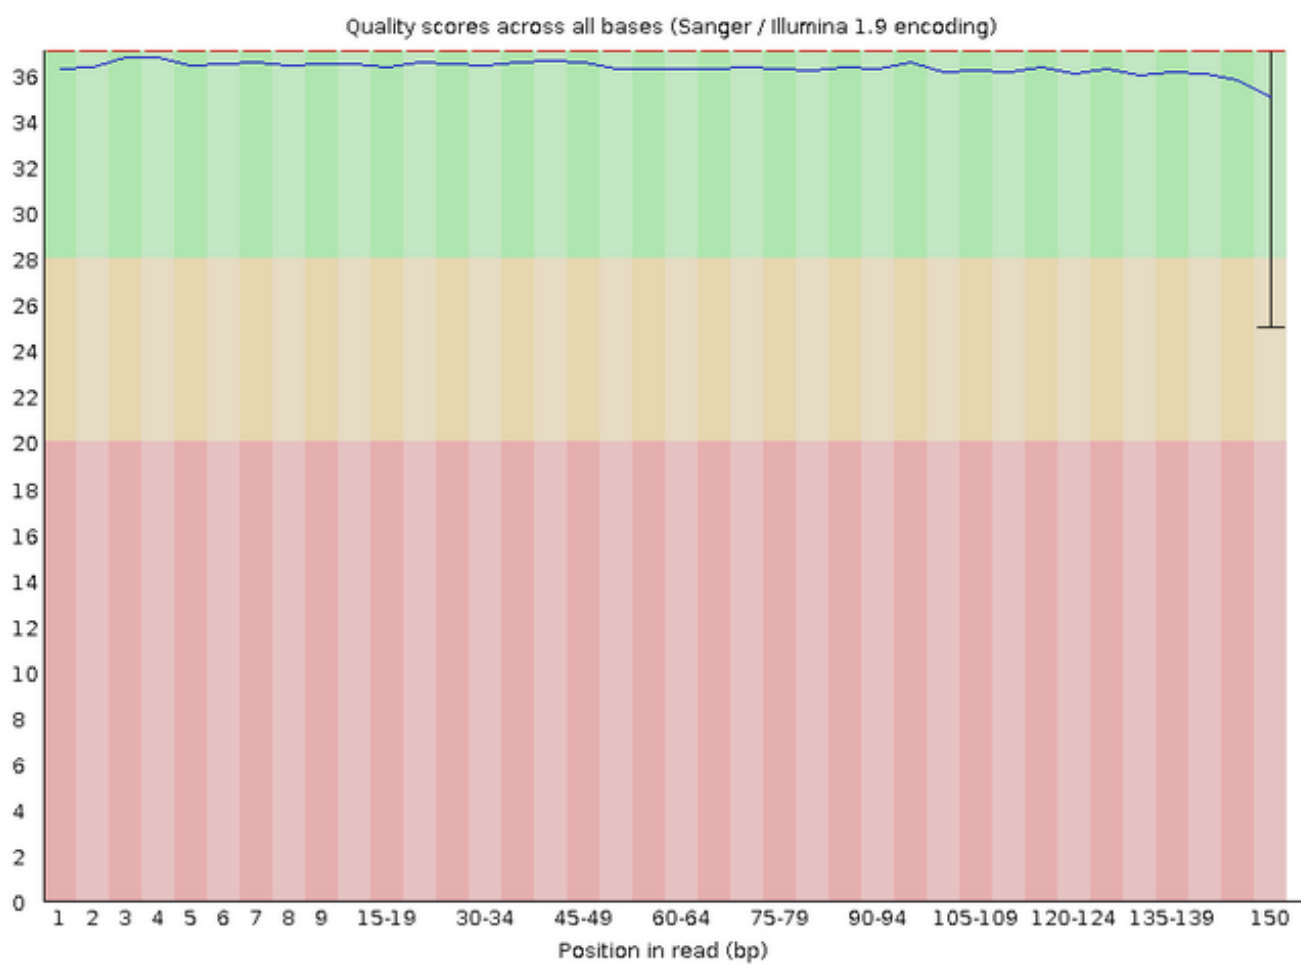
Summary

- ✔ [Basic Statistics](#)
- ✔ [Per base sequence quality](#)
- ✔ [Per sequence quality scores](#)
- ✖ [Per base sequence content](#)
- ✔ [Per sequence GC content](#)
- ✔ [Per base N content](#)
- ✔ [Sequence Length Distribution](#)
- ✖ [Sequence Duplication Levels](#)
- ✔ [Overrepresented sequences](#)
- ✔ [Adapter Content](#)
- ✖ [Kmer Content](#)

✔ Basic Statistics


Measure	Value
Filename	Sample1.R1.fastq.gz
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	28002712
Sequences flagged as poor quality	0
Sequence length	150
%GC	43

✔ **Per base sequence quality**




Per base sequence quality（每个碱基的序列质量）：横轴为read长度，纵轴为质量得分，显示测序reads中每个碱基的平均质量值。

✔ **Per sequence quality scores**



Per sequence quality scores（序列质量评分的分布）：横轴平均序列质量（Phred Score），纵轴表示每个值对应的read数目，显示每个reads的质量分数分布，用于评估测序数据的质量。

✔ **Sequence Length Distribution**




Sequence length distribution（序列长度分布）：这个图表显示了reads的长度分布，用来评估文库制备的效果和测序的准确性。

数据质控


质控软件：fastqc

✗ Per base sequence content




Per base sequence content (每个碱基的分布)：横轴为碱基位置，纵轴表示百分比，显示测序reads中每个碱基的四种核苷酸分布情况，用来评估是否存在GC偏好或AT富集等问题。

✓ Per sequence GC content



Per sequence GC content (每个reads的GC含量)：红线是实际情况，蓝线是理论分布。显示了每个reads的GC含量分布情况，用来评估GC含量的均匀性和偏差

✓ Per base N content



Per base N content (每个碱基的N含量)：横轴为碱基分布，纵轴为N比率。显示了在测序数据中，每个碱基位置上"N"的百分比或比例。

gRNA 序列提取与统计

03

提取sgRNA序列软件：cutadapt

为了验证sgRNA序列在载体中位置的正确性，并检查其上下游序列是否符合设计要求，需要先提取sgRNA，保留靶向识别核心序列，从而生成gRNA核心序列的FASTQ文件，用于后续的比对统计。

```
cutadapt -g CACCG...GTTTT -m 19 -M 21 -q 20 --max-n 0 --discard-untrimmed  
00.Raw_data/${sam}_1.fq.gz  
--report=full/minimal -o 02.clean_data/${sam}_trimed.fq > ${sam}.log
```

参数：

- g CACCG...GTTTT：指定切除的序列模式，这里是保留以 CACCG 开头，以 GTTTT 结尾的序列。中间包含任意数量的碱基。
- m：指定最短允许的修剪后序列的长度。
- M：指定最长允许的修剪后序列的长度。
- q 20：指定了最低允许的质量阈值，即保留序列中的碱基质量值不低于 20。
- max-n 0：指定了允许的最大 N 的数量，这里设置为 0，表示不允许序列中存在 N。
- discard-untrimmed：如果序列中没有找到匹配的适配器序列，则丢弃该序列。
- report=full/minimal：要打印的报告类型。
- o：输出文件。

gRNA 提取与统计

查看运行结果

\$ ll -h

```
Sample1_trimmed.fq.gz  
Sample1.log
```

\$ cat Sample1.log

```
=== Summary ===  
  
Total reads processed:          28,002,712  
Reads with adapters:           27,425,954 (97.9%)  
  
== Read fate breakdown ==  
Reads that were too short:      731,484 (2.6%)  
Reads that were too long:      1,480,702 (5.3%)  
Reads with too many N:         0 (0.0%)  
Reads discarded as untrimmed:   6 (0.0%)  
Reads written (passing filters): 25,790,520 (92.1%)  
  
Total basepairs processed: 4,200,406,800 bp  
Quality-trimmed:           1,467,933 bp (0.0%)  
Total written (filtered):    515,810,400 bp (12.3%)
```

gRNA 比对与数目统计

04

gRNA 比对

比对软件: mageck count

```
gunzip -cd 02.clean_data/${sam}_trimmed.fq.gz > ${Sam1}.fq
```

```
mageck count --trim-5 0 -l ${Library} -n 03.gRNA_count/mageck --sample-label ${Sam1}, ${Sam2} --fastq  
${Sam1}.fq, ${Sam2}.fq --sgrna-len 20 --unmapped-to-file --norm-method control --control-sgrna "${Control}"
```

参数:

- trim-5 0: 对输入的序列不进行5'端修剪。
- l: 指定CRISPR gRNA文库的文件名。
- n: 输出文件的路径和文件前缀
- sample-label: 样本的名称
- fastq: 输入的FASTQ文件的路径
- sgrna-len: gRNA 的长度。
- unmapped-to-file: 将未匹配到的序列保存到文件中。--norm-method control: 指定了进行数据标准化的方法。
- control-sgrna "\${Control}": 指定对照样本gRNA 序列信息。

Li et al. *Genome Biology* 2014, **15**:554
<http://genomebiology.com/2014/15/12/554>



METHOD

Open Access

MAGeCK enables robust identification of essential genes from genome-scale CRISPR/Cas9 knockout screens

Wei Li^{1,2†}, Han Xu^{1,2†}, Tengfei Xiao^{2,3}, Le Cong^{4,6}, Michael I Love¹, Feng Zhang^{5,6}, Rafael A Irizarry¹, Jun S Liu⁷, Myles Brown^{2,3,8} and X Shirley Liu^{1,2*}

均一化方法

不同的项目或样本测得的数据量可能存在差异，因此需要将这些数据进行均一化处理，使得它们可以在同一个维度上进行比较。

三种常用均一化方法：

推荐度： **negative control** > **median** > **total**

Negative Control: 许多sgRNA文库在设计时会包含一些non-targeting sgRNA，这些sgRNA不靶向任何基因，被用作内部的阴性对照，可以有效地减少由于测序深度差异和其他技术变异带来的噪音，从而提高分析的准确性。

Median (中位数)： 使用所有sgRNA的reads counts的中位数来进行标准化，稳健性较好。

Total (总reads数)： 这使用每个样本的总reads数进行标准化。

查看运行结果

主要文件:

\$ cat mageck.countsummary.txt

File	Label	Reads	Mapped	Percentage	TotalsgRNAs	Zerocounts	GiniIndex
Sample1_trimmed.fq.gz	Sample1	25790520			24446231	0.9479 63950	376 0.07008

\$ cat mageck.count.txt

sgRNA	Gene	Sample1	Sample2
HGLibA_16256	FAM169B	547	547
HGLibA_39766	R3HCC1	247	247
HGLibA_54928	ZBTB8B	531	531
HGLibA_16879	FARS2	526	526
HGLibA_17553	FKBP10	426	426
HGLibA_25094	KLHDC10	442	442
HGLibA_53180	USH2A	414	414
HGLibA_39980	RAB7A	495	495
HGLibA_49271	TGM7	397	397

\$ cat mageck.count_normalized.txt

sgRNA	Gene	Sample1	Sample2
HGLibA_16256	FAM169B	548.5322128851541	548.5322128851541
HGLibA_39766	R3HCC1	247.6918767507003	247.6918767507003
HGLibA_54928	ZBTB8B	532.4873949579832	532.4873949579832
HGLibA_16879	FARS2	527.4733893557423	527.4733893557423
HGLibA_17553	FKBP10	427.1932773109244	427.1932773109244
HGLibA_25094	KLHDC10	443.23809523809524	443.23809523809524
HGLibA_53180	USH2A	415.15966386554624	415.15966386554624
HGLibA_39980	RAB7A	496.38655462184875	496.38655462184875
HGLibA_49271	TGM7	398.11204481792714	398.11204481792714

测序深度、覆盖度及均一性评估

05

测序深度、覆盖度及均一性评估

gRNA 测序深度柱状图


```
$ python hist.py
```

```
# 导入pandas库，用于数据处理和分析  
import pandas as pd
```

```
# 导入matplotlib库的pyplot模块，用于绘图  
import matplotlib.pyplot as plt
```

```
# 导入numpy库，用于数值  
import numpy as np
```


```
# 读取数据的文件，制表符（tab）作分隔符  
counts = pd.read_csv('mageck.count.txt', sep='\t')
```



测序深度、覆盖度及均一性评估

gRNA 测序深度柱状图

```
#对'Sample1'列的值进行log2变换  
log2_counts = np.log2(counts['Sample1'] + 1)  
  
# 绘制直方图，使用'log2_counts'数据，颜色为深天蓝色  
plt.hist(log2_counts, facecolor='deepskyblue')  
  
# 设置x轴标签  
plt.xlabel('log2 Sequencing depth')  
  
# 设置y轴标签  
plt.ylabel('Number of sgRNAs')  
  
# 保存图像  
plt.savefig('Sample1_ReadsHist.png')
```



测序深度、覆盖度及均一性评估

覆盖度

```
$ python sum.py
```

```
import pandas as pd      # 导入pandas库，用于数据处理和分析
import numpy as np       # 导入numpy库，用于数值计算
```

```
df = pd.read_csv('mageck.countsummary.txt', sep='\t')      # 读取数据的文件
```

```
sample1_row = df[df.iloc[:, 1] == 'Sample1']              # 获取'Sample1'的行
```

```
total_grnas = sample1_row.loc[:, 'TotalsgRNAs'].values[0]  # 获取总sgRNA数
```

```
zero_counts = sample1_row.loc[:, 'Zerocounts'].values[0]  # 获取计数为零的sgRNA数
```

```
# 计算覆盖率，结果保留两位小数并添加百分号
```

```
coverage_rate = "{:.2f}%".format((float(total_grnas - zero_counts) / float(total_grnas)) * 100)
```

测序深度、覆盖度及均一性评估



均一性分析

分布斜率(Skew Ration)为累积分布达到90%时对应的 gRNA 数目与累积分布达到10%时对应的 gRNA 数目的比值。该值可以直接反应文库的均一性，一般认为， $Skew\ Ration < 10$ ，则文库均一性合格。文库的均一性还可以参考Giniindex，该值越小文库均一性越好。

```
# 读取数据文件
counts = pd.read_csv('mageck.count.txt', sep='\t')

# 计算第90百分位数
dep_90 = np.percentile(counts['Sample1'], 90)

# 计算第10百分位数
dep_10 = np.percentile(counts['Sample1'], 10)

# 计算90百分位数与10百分位数的比值，并四舍五入保留两位小数
skew_ratio = round(dep_90 / dep_10, 2)
```

Skew_ratio	4.35
Top10_Counts	657
Bottom10_Counts	151
Max_Depth	1740
Mean_Depth	388
Median_depth	364
Coverage_Rate	99.14%

测序深度、覆盖度及均一性评估



```
# 获取最大值
max_depth = counts['Sample1'].max()

# 计算平均值并转换为整数
mean_depth = int(counts['Sample1'].mean())

# 计算中位数并转换为整数
median_depth = int(counts['Sample1'].median())
```

Skew_ration	4.35
Top10_Counts	657
Bottom10_Counts	151
Max_Depth	1740
Mean_Depth	388
Median_depth	364
Coverage_Rate	99.14%

常见问题

06

为什么ZerosgRNA较多，而Zerogenes很少？

- ZerosgRNA 是文库中存在而在 clean reads 中未测到的 sgRNA；Zerogenes 是文库中存在而在 clean reads 中未测到的基因。
- 通常情况下，一个基因会设计多条sgRNA，如果该条sgRNA未测到，则认为该条sgRNA丢失；
- 而只有当某基因对应的多条sgRNA都未检测到，才会认为该基因丢失，因此这种情况是正常的。



如何评价文库质检（仅适用于质粒样本）的结果？ 需要看哪些指标？

文库质检主要看文库的均一性和覆盖度，可以根据有效数据率，比对率，丢失的sgRNA和基因数，sgRNA测序深度柱状图，Giniindex以及SkewRation等参数进行全方面评价。常见的文库评价标准指标如下：

有效数据率：>90%;

比对率：>90%;

ZerosgRNA：一般<100;

Zerogenes：一般<10;


sgRNA测序深度柱状图：呈泊松分布;

Giniindex：<0.1;

SkewRation：<10

符合以上标准则文库质量很好。

Thank you!



AZENTA 安升达
LIFE SCIENCES