






AZENTA 安升达
LIFE SCIENCES

Guide-Advance 数据分析培训

吴晓红



Guide-Advance 分析流程图



- 数据拆分和质控：使用cutadapt软件对原始数据进行拆分和质控，去除低质量reads，获得clean reads；
- 基因组比对：使用bwa软件将校正的reads比对到参考基因组；
- 脱靶分析：使用GUIDE-Advance 脚本分析潜在脱靶位置，获得靶位点处的基因组序列。

Guide-Advance 分析软件



所需软件列表：

- Cutadapt <https://cutadapt.readthedocs.io/en/stable/installation.html>
- bwa <http://sourceforge.net/projects/bio-bwa/files/bwa-0.7.17.tar.bz2>
- samtools <https://sourceforge.net/projects/samtools/files/samtools/>
- bedtools <https://github.com/arq5x/bedtools2/releases/download/v2.30.0/bedtools-2.30.0.tar.gz>
- python <https://www.python.org/downloads/>

推荐使用Conda安装：

#Cutadapt

```
conda config --add channels bioconda
conda config --add channels conda-forge
conda config --set channel_priority strict
conda create -n cutadapt cutadapt
```

#bwa

```
conda create -n bwa-env
conda activate bwa-env
conda install -c bioconda bwa
```

#samtools

```
conda create -n samtools-env
conda activate samtools-env
conda install -c bioconda samtools
```

#bedtools

```
conda create -n bedtools-env
conda activate bedtools-env
conda install bedtools
```


数据拆分和质控

01

1.2 核查数据

核查测序数据的路径是否正确：

```
$ ll -h /CRISPR/Guide-Advance/data/G1-F-N.*.fq.gz
```

准备实操数据：

```
mkdir Guide-Advance ; cd Guide-Advance  
mkdir shell;cd shell  
cp /CRISPR/Guide-Advance/shell/*sh ./  
cp /CRISPR/Guide-Advance/shell/*py ./
```

1.3 数据拆分/质控

```
###G1-F-N.barcode1.cut.sh  
mkdir 01.Cleandata ;cd 01.Cleandata
```

下面命令中红色是ODN序列，黄色是barcode 序列

```
cutadapt -g ^ACATATGACAACCTCAATTAAACAAGCAG -m 38 -q 20 -O 28 --max-n 4 -e 0  
--discard-untrimmed -o G1-F-N.barcode1.1.fq /CRISPR/Guide-Advance/data/G1-F-  
N.1.fq.gz
```

- g ^ACATATGACAACCTCAATTAAACAAGCAG: 指定要修剪的 5' 端接头序列 (adapter sequence)。在这个例子中，接头序列是 ACATATGACAACCTCAATTAAACAAGCAG，^ 表示必须在序列的开头匹配。
- m 38: 指定修剪后的读段最小长度。任何长度小于 38 个碱基的读段将被丢弃。
- q 20: 质量过滤，修剪低质量碱基。此参数表示将 3' 端的碱基修剪到质量分数至少为 20。
- O 28: 最小重叠长度。接头序列和读段之间必须至少有 28 个碱基匹配，才能进行修剪。
- max-n 4: 最大允许的 N 碱基数。此参数表示包含超过 4 个 N 碱基的读段将被丢弃。
- e 0: 允许的最大错误率。此参数表示不允许任何匹配错误 (即 0% 的错误率)。
- discard-untrimmed: 丢弃未修剪的读段。如果读段中没有找到接头序列，则该读段将被丢弃。



1.4 查看质控结果

查看运行结果：

##质控后数据

```
$ less -SN G1-F-N.barcode1.1.fq
```

[illegible]

##原始数据

```
$ less -SN /CRISPR/Guide-Advance/data/G1-F-N.1.fq.gz
```

[illegible]

参考基因组比对

02

2.1 hg38 参考基因组下载

##参考基因组下载链接

`wget http://hgdownload.soe.ucsc.edu/goldenPath/hg38/bigZips/hg38.fa.gz`

##下载md5 check 的文件

`wget http://hgdownload.soe.ucsc.edu/goldenPath/hg38/bigZips/md5sum.txt`

md5 文件check

`md5sum -c md5sum.txt`

2.2 hg38 参考基因组索引建立

##这个步骤大约需要1~2h

```
bwa index hg38.fa
```

运行bwa index命令后，会生成以下几种文件：

hg38.fa.amb：含有A/T的二元位图

hg38.fa.ann：注释文件

hg38.fa.bwt：Burrows-Wheeler变换后的参考基因组

hg38.fa.pac：压缩后的参考基因组

hg38.fa.sa：后缀数组文件

这些文件是对参考基因组进行快速比对所必需的。

2.3 将测序数据比对到hg38

```
### G1-F-N.barcode1.align.sh
```

```
mkdir 02.Align ;cd 02.Align
```

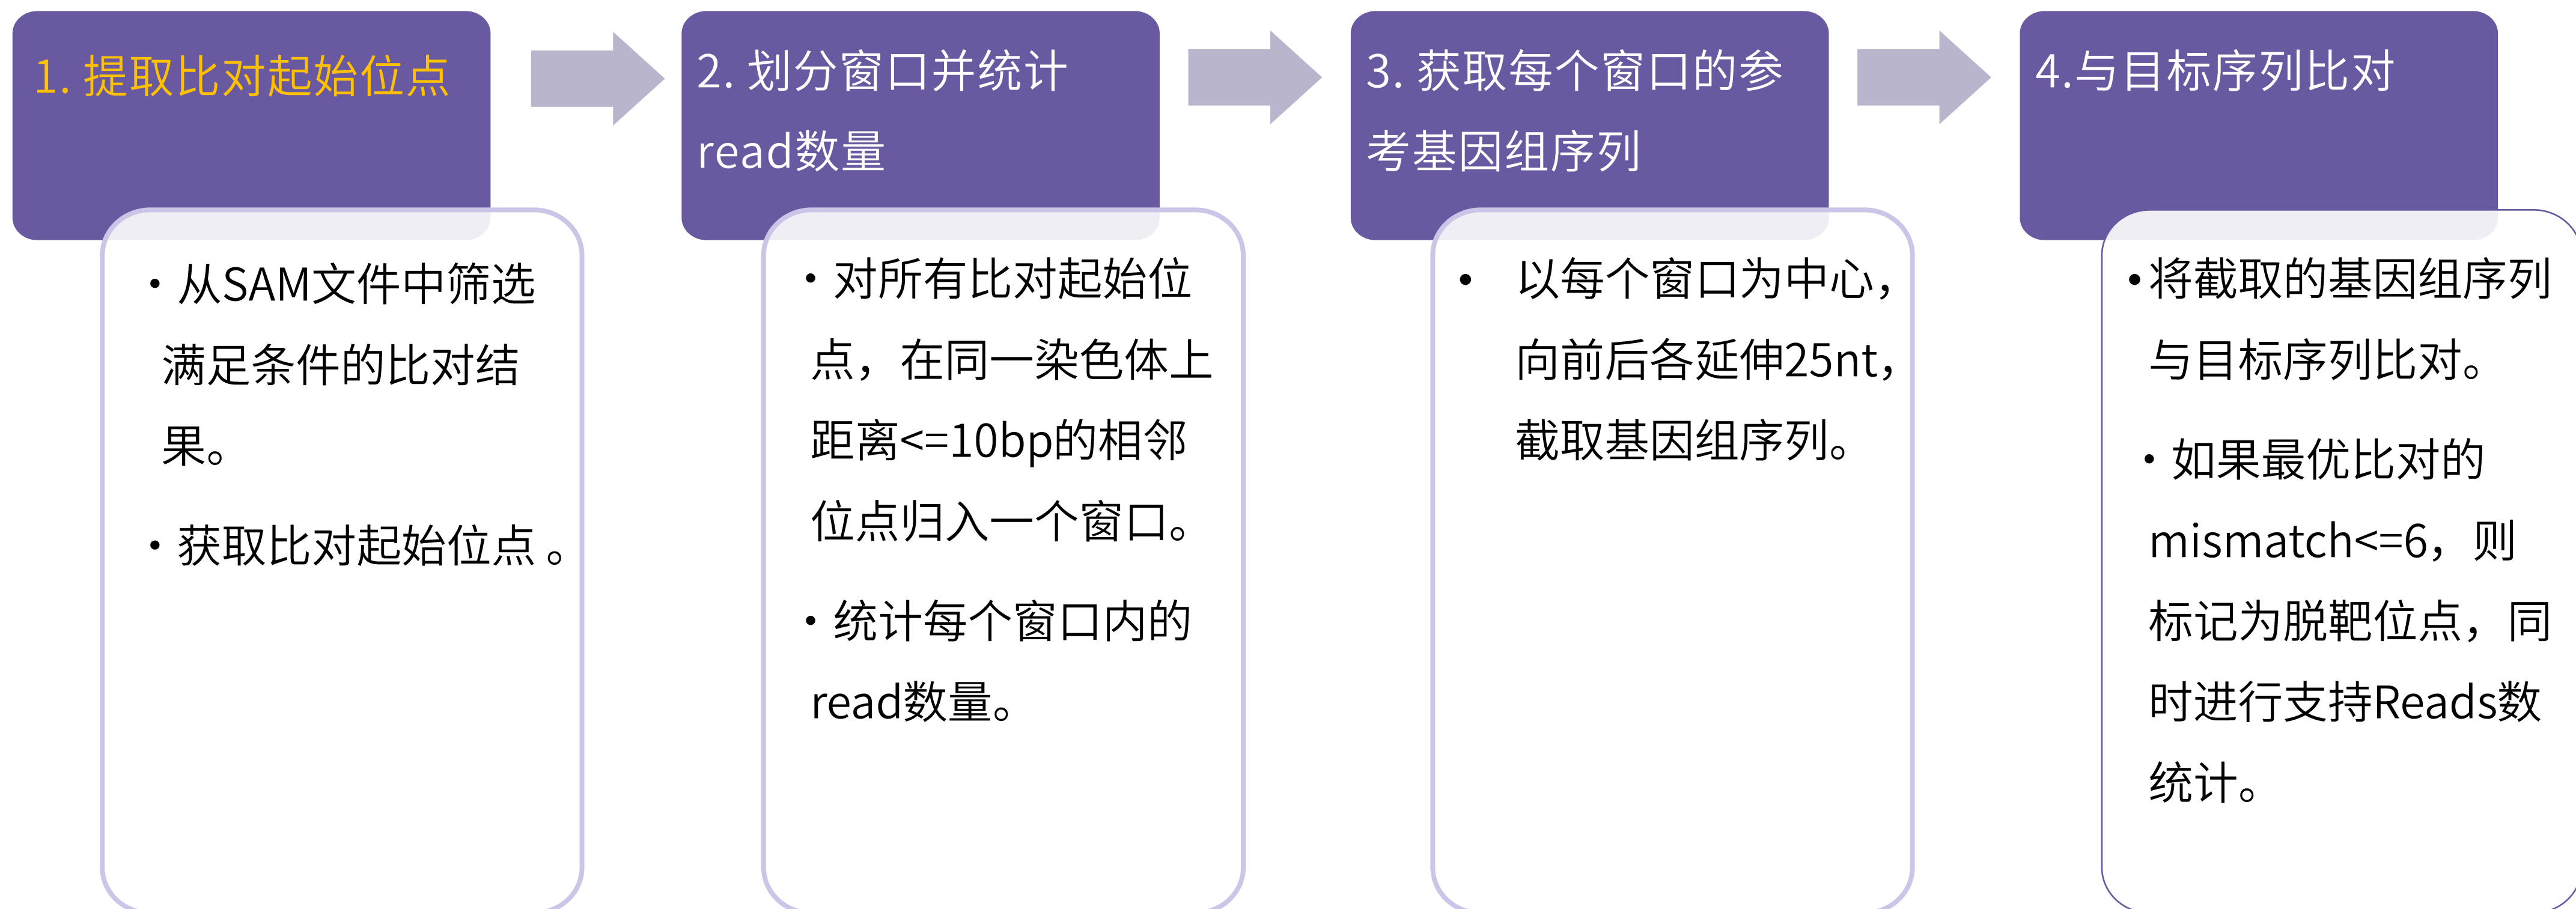
```
## 将比对结果保存为sam 格式
```

```
bwa mem /CRISPR/Guide-Advance/ref/hg38.fa ../01.Cleandata/G1-F-N.barcode1.1.fq >  
G1-F-N.barcode1.sam
```


中靶、脱靶分析

03

脱靶分析思路流程图



3.1 提取比对起始位点

```
###G1-F-N.barcode1.offdect.sh  
mkdir 03.offtarget ;cd 03.offtarget
```

筛选满足比对条件的结果，sam 文件中第5列是对比质量值；第2列是对比flag 值，2024 代表是次比对位置。

```
samtools view -h ../ 02.Align /G1-F-N.barcode1.sam | awk 'BEGIN {OFS="\t"} $1 ~ /^@/ ||  
($5 >= 50 && and($2, 2048) == 0)' > filtered.sam
```


3.1 提取比对起始位点

```
###G1-F-N.barcode1.offdect.sh
```

```
##获取比对起始位置
```

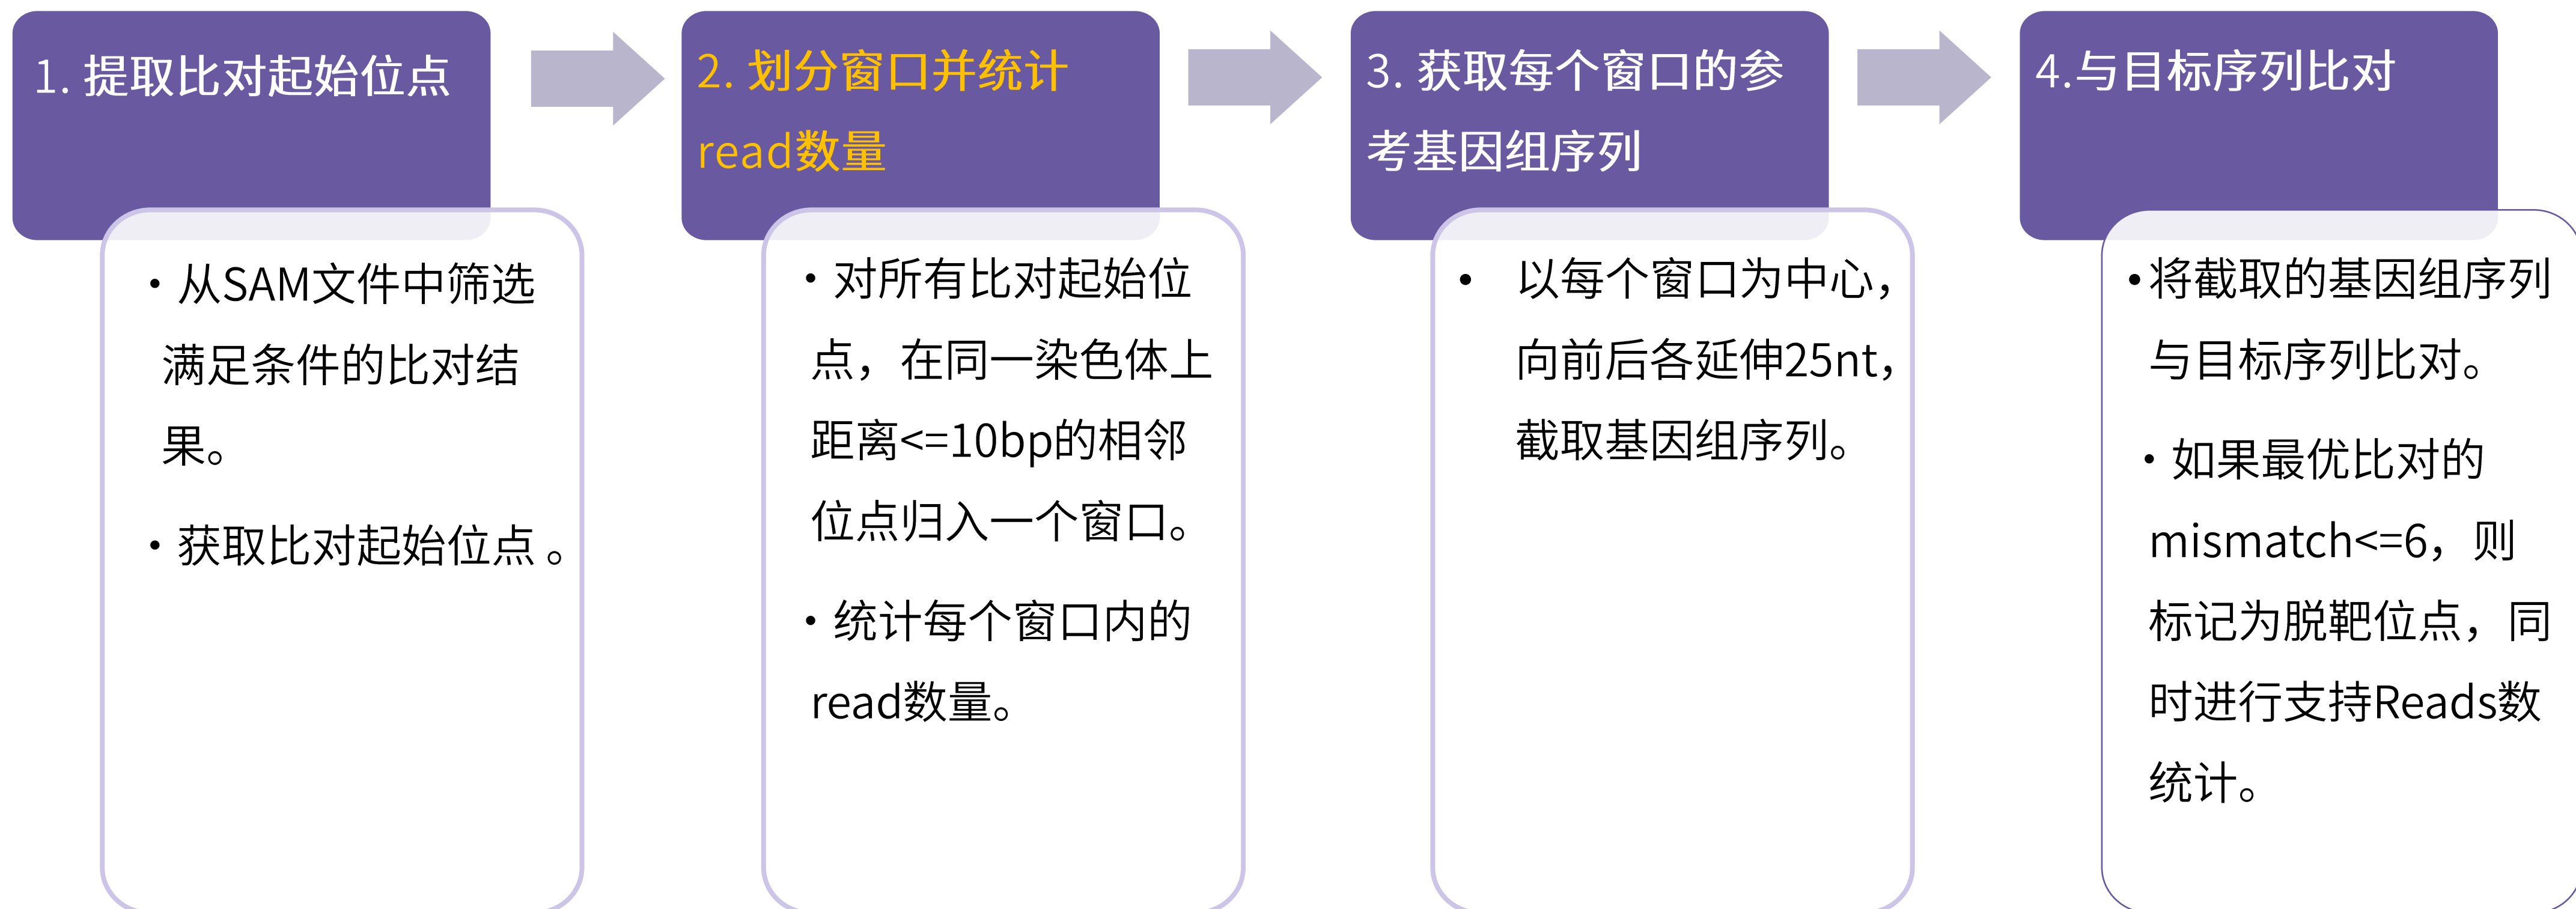
```
samtools view filtered.sam | awk '{print $3"\t"$4-1"\t"$4}' >
```

```
start_positions_unsorted.bed
```

```
## 比对起始位置进行排序
```

```
sort -k1,1 -k3,3n start_positions_unsorted.bed > start_positions.bed
```

脱靶分析思路流程图



3.2 划分窗口并统计read数量

```
###G1-F-N.barcode1.offdect.sh
```

```
bedtools merge -i start_positions.bed -d 10 -c 3 -o count > windows.bed
```

##主要参数解释

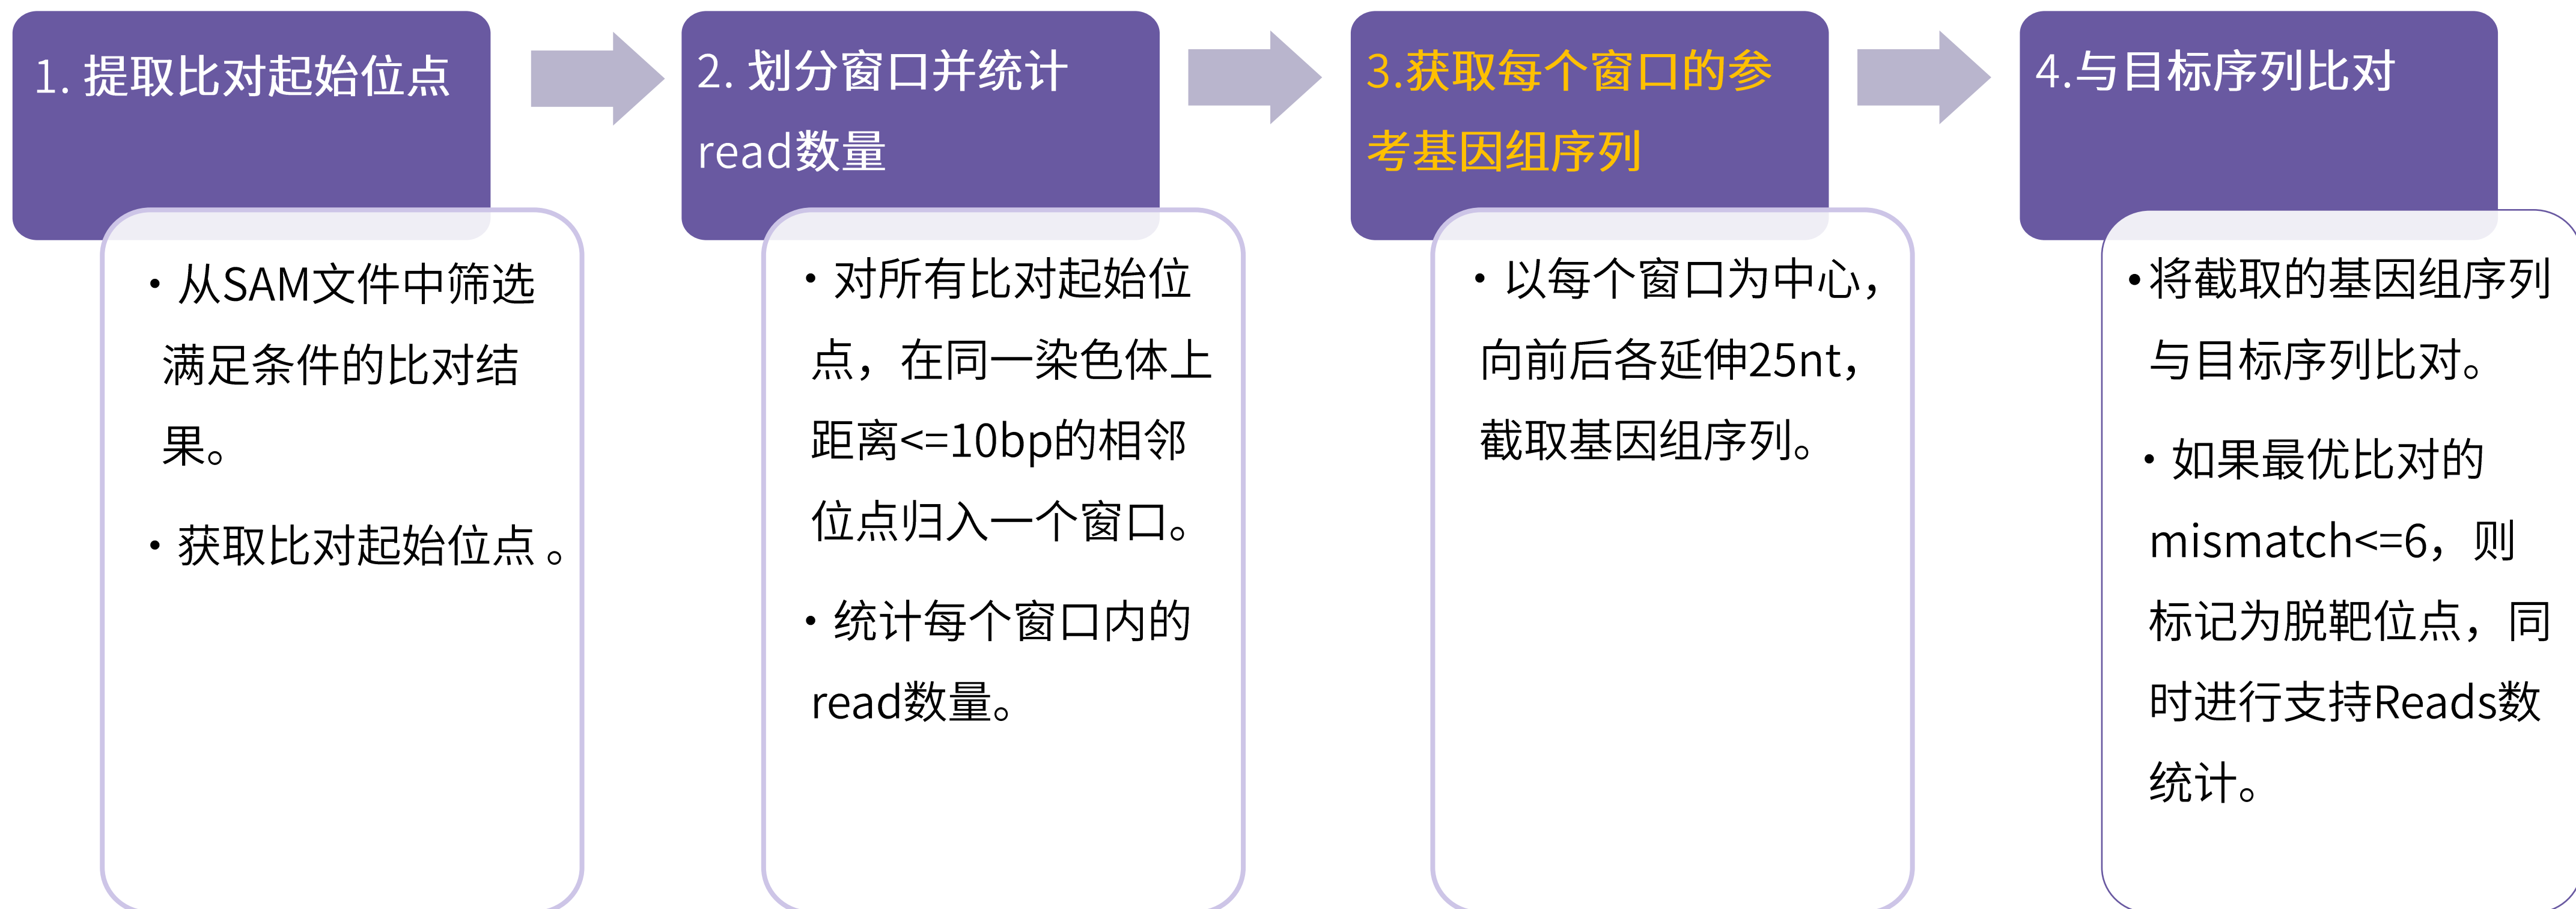
bedtools merge: 这是一个用于合并重叠或相邻的BED格式区间的工具。

-d 10: 设置允许合并的最大间隔距离为10个碱基对。如果两个区间之间的距离小于或等于10个碱基对，则这些区间会被合并。

-c 3: 指定要汇总的列。这里是第3列，是测序reads计数。

-o count: 指定对第3列执行的操作为计数。这意味着在合并的区间中，第2列的值将被计数并作为输出的一部分。

脱靶分析思路流程图



3.3 获取每个窗口的参考基因组序列

```
###G1-F-N.barcode1.offdect.sh
```

##以窗口为中心，向前后各延伸25nt，获取参考基因组位置。

```
bedtools slop -i windows.bed -g /CRISPR/Guide-Advance/ref/hg38.fa.fai -b 25 >  
extended_positions.bed
```

这个命令使用bedtools slop工具对max_read_positions.bed文件中的每个区间进行扩展，并将结果输出到extended_positions.bed文件中。具体参数和操作如下：

命令解析

- bedtools slop: bedtools中的一个工具，用于调整（扩展或收缩）BED文件中每个区间的范围。
- i max_read_positions.bed: 指定输入的BED文件为max_read_positions.bed。
- g hg38.fa.fai: 指定基因组索引文件，用于确保扩展的区间不会超出染色体的边界。hg38.fa.fai是hg38基因组的FASTA索引文件，包含染色体的名称和长度信息。使用samtools faidx hg38.fa 构建。
- b 25: 在每个区间的起始位置和结束位置各扩展25个碱基对。-b参数表示在区间的两端增加的碱基对数量。

3.3 获取每个窗口的参考基因组序列

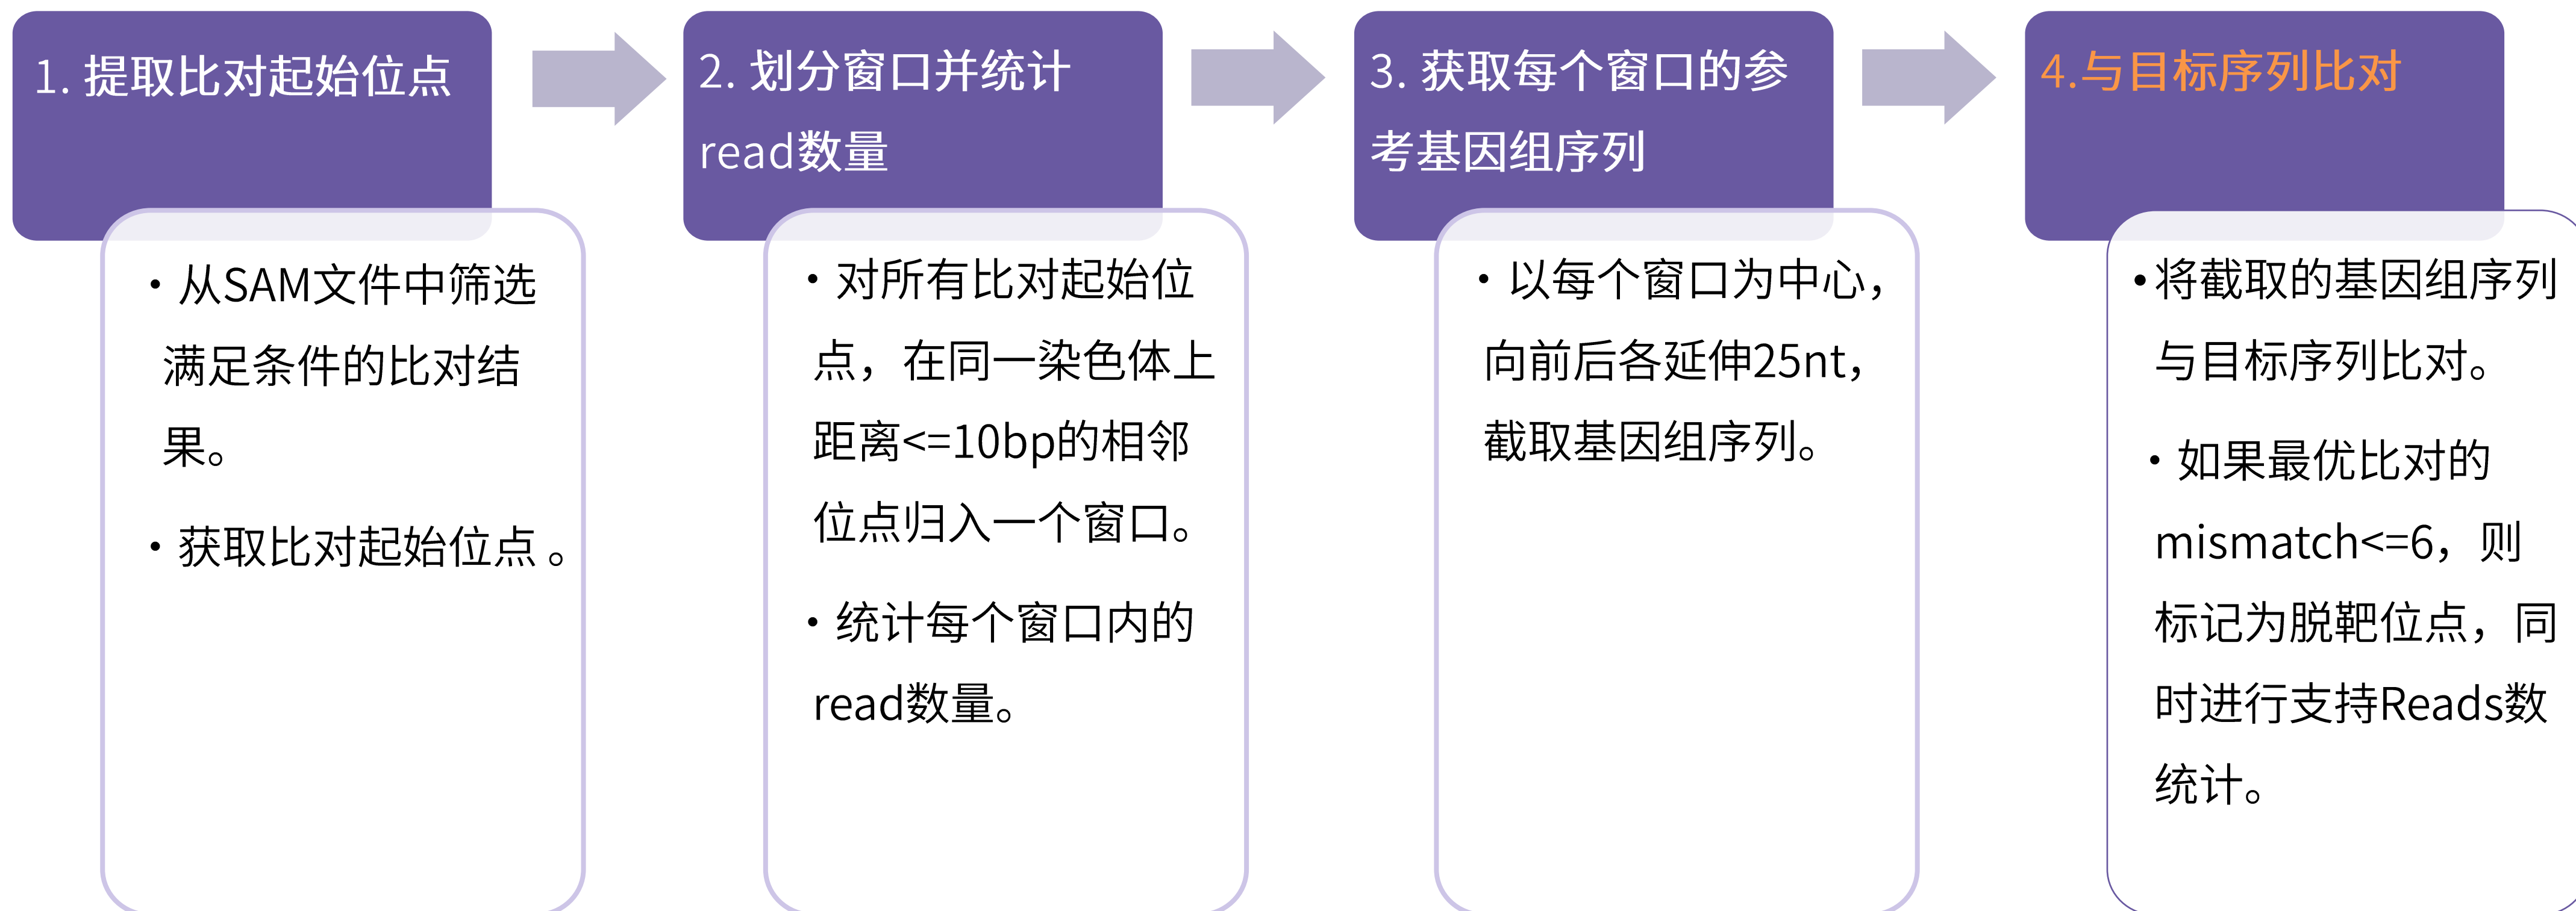
##以窗口为中心，向前后各延伸25nt，获取参考基因组位置。

```
###G1-F-N.barcode1.offdect.sh
```

```
bedtools getfasta -fi /CRISPR/Guide-Advance/ref/hg38.fa -bed  
extended_positions.bed -fo extended_sequences.fa
```

- 这个命令使用bedtools getfasta工具从参考基因组序列中提取指定区间的序列，并将结果输出到一个FASTA文件中。以下是这个命令的详细解释：
- 命令解析
- bedtools getfasta：这是bedtools套件中的一个工具，用于从基因组中提取指定区间的DNA序列。
- -fi hg38.fa：指定输入的参考基因组文件，这里是hg38.fa，它位于../ref/目录下。这个文件包含人类参考基因组序列（hg38版本）。
- -bed extended_positions.bed：指定输入的BED文件extended_positions.bed，该文件包含要从基因组中提取的区间信息。
- -fo extended_sequences.fa：指定输出的FASTA文件名extended_sequences.fa，用来存储从参考基因组中提取的序列。

脱靶分析思路流程图



3.4与目标序列比对

```
### G1-F-N.barcode1.offdetect.sh  
  
python3.7 off_detect.py > off_detect.out.txt  
less -SN off_detect.out.txt |grep -A 11 Query > off_target.txt
```


3.4 与目标序列比对步骤--python 脚本详解

1. 反向互补函数

```
def reverseComplement(sequence):  
    transtab = str.maketrans("ACGT", "TGCA")  
    return sequence.translate(transtab)[::-1]
```

- 目的：计算给定DNA序列的反向互补序列。
- 过程：
 - 使用str.maketrans生成一个翻译表，将'A'替换为'T'，'C'替换为'G'，'G'替换为'C'，'T'替换为'A'。
 - 将翻译后的字符串反转，得到反向互补序列。

3.4 与目标序列比对步骤--python 脚本详解



AZENTA 安升达
LIFE SCIENCES

2. 序列比对函数

```
def alignSequences(ref_seq, query_seq, totalmismatch):
    match = 4
    mismatch = -1
    ref_length = len(ref_seq)
    matches_required = len(ref_seq) - totalmismatch # 允许的错配数
    scoring = swalign.NucleotideScoringMatrix(match, mismatch)
    sw = swalign.LocalAlignment(scoring, gap_penalty=-100, gap_extension_penalty=-100,
    prefer_gap_runs=True)

    forward_alignment = sw.align(ref_seq, query_seq)
    reverse_alignment = sw.align(ref_seq, reverseComplement(query_seq))

    def get_alignment_info(alignment, strand):
        start = alignment.q_pos
        end = alignment.q_end
        return [alignment.query[start:end], strand]
```

3.4 与目标序列比对步骤--python 脚本详解

2. 序列比对函数

- ◆ 目的：将参考序列ref_seq与查询序列query_seq及其反向互补序列进行比对。
- ◆ 参数：
 - match：匹配得分。
 - mismatch：错配惩罚。
 - gap_penalty和gap_extension_penalty：设置了非常高的间隙惩罚值，以确保比对倾向于匹配而不是引入间隙。
- ◆ 比对逻辑：
 - 使用Smith-Waterman算法计算正向和反向互补比对。
 - 比较正向和反向互补比对的匹配数，如果匹配数足够且正向或反向互补比对的匹配数更大，则选择相应的比对。
 - 如果正向和反向互补比对的匹配数相等且均满足要求，则优先选择正向比对。
 - 如果都不满足，则返回空结果。


3.4 与目标序列比对步骤--python 脚本详解

3. 读取FASTA文件的函数

```
def read_fasta(file_path):  
    headers = []  
    sequences = []  
    with open(file_path, "r") as file:  
        for line in file:  
            line = line.strip()  
            if line.startswith(">"):  
                headers.append(line[1:])  
                sequences.append("")  
            else:  
                sequences[-1] += line  
    return headers, sequences
```

- 目的：从FASTA文件中读取序列。
- 过程：读取文件中的每一行，如果是以>开头的行，则表示一个新的序列头部；否则将行内容附加到当前序列。

3.4 与目标序列比对步骤--python 脚本详解



4. 主程序代码

```
string2 = "GGGAAAGACCCAGCATCCGTGGG"  
fasta_file = "extended_sequences.fa"  
headers, sequences = read_fasta(fasta_file)  
  
for idx, (header, seq) in enumerate(zip(headers, sequences)):  
    alignment_result = alignSequences(string2, seq, 6)  
    print(f"Alignment for sequence {idx + 1}:")  
    print(f"Header: {header}")  
    print(alignment_result)
```

- ◆ 功能：将给定的参考序列string2与从FASTA文件中读取的每个序列进行比对。
- ◆ 参数：
 - string2：参考序列。
 - fasta_file：包含查询序列的FASTA文件。
 - totalmismatch：允许的最大错配数（设置为6）。
- ◆ 输出：对每个查询序列，输出其头部信息和比对结果。

3.5 中靶位点结果



查看中靶分析的结果

less -SN off_target.txt

```
235 Query: 10 GGGAAAGACCCAGCATCCGTGGG 32
236      |||
237 Ref : 1 GGGAAAGACCCAGCATCCGTGGG 23
238
239 Score: 92
240 Matches: 23 (100.0%)
241 Mismatches: 0
242 CIGAR: 23M
243 None
244 Alignment for sequence 31236:
245 Header: chr9:107341397-107341466
246 ['GGGAAAGACCCAGCATCCGTGGG', '+']
```

中靶位置：

chr : chr9

Start : 107341407 (107341397+10)

序列：GGGAAAGACCCAGCATCCGTGGG

支持序列数：669

```
less -SN extended_positions.bed | grep
107341397
```

```
(base) crispr001@iZbp18758pdxsp0rsgmsuhZ:~/c
chr9      107341397      107341466      669
```


3.6 脱靶位点结果



查看脱靶分析的结果

共检测到19个中脱靶位点，以一个脱靶位置为例，进行展示

```
less -SN off_target.txt | grep "\-\"|wc -l  
less -SN off_target.txt
```

```
27 Query: 11 GGGAAAGTCCCAGCATCCTTTGG 33  
28          |||||.||||||||.|.||  
29 Ref :   1 GGGAAAGACCCAGCATCCGTGGG 23  
30  
31 Score: 77  
32 Matches: 20 (87.0%)  
33 Mismatches: 3  
34 CIGAR: 23M  
35 None  
36 Alignment for sequence 2527:  
37 Header: chr1:202023285-202023351  
38 ['GGGAAAGTCCCAGCATCCTTTGG', '+']
```

脱靶位置:
chr : chr1

Start : 202023296 (202023285+11)

序列 : GGGAAAGTCCCAGCATCCTTTGG


支持序列数 : 65

Mismatch: 3

```
less -SN extended_positions.bed | grep  
202023285
```

```
(base) crispr001@iZbp18758pdxsp0rsgmsuhZ:~/Guide-Ad  
chr1      202023285      202023351      65
```

Thank you!



AZENTA 安升达
LIFE SCIENCES