




AZENTA 安升达
LIFE SCIENCES

Seurat软件应用介绍

转录组事业部


2024年/07月/13日

目录

软件介绍	01
细胞质量控制	02
基础分析	03
分析拓展	04

软件介绍

01




Seurat主要是由Satija Lab开发的单细胞数据分析集成软件包，主要用于单细胞RNA-seq数据的质控、分析以及可视化。

- Hao, et al., Nature Biotechnology 2023 [Seurat v5]
- Hao*, Hao*, et al., Cell 2021 [Seurat v4]
- Stuart*, Butler*, et al., Cell 2019 [Seurat v3]
- Butler, et al., Nat Biotechnol 2018 [Seurat v2]
- Satija*, Farrell*, et al., Nat Biotechnol 2015 [Seurat v1]

Seurat软件主要应用

- 细胞亚群鉴定
- 多组学数据整合分析
- 细胞发育和分化轨迹分析
- 空间转录组分析


Seurat分析流程



细胞质量控制

02


Seurat输入数据



```
rna <- Read10X(data.dir = rnafile)
```


```
object <- CreateSeuratObject(counts = rna, project = sample)
```


文库组成




A single happy cell in a droplet is ideal

- Complex transcriptome
- Average number of genes detected




Empty droplet: No cell in a droplet

- No genes detected




Droplet with ambient RNA

- Low complex transcriptome
- Genes detected much lower than average genes per cell



Droplet with dead cell

- Enriched for mitochondrial genes



Droplet with multiple cell

- Very complex transcriptome
- Genes detected much higher than average genes per cell




Droplet



Cell




Floating RNA




Dead cell


质量控制



```
object[["percent.mt"]] <- PercentageFeatureSet(object, pattern = "^MT-")  
VlnPlot(pbmc, features = c("nFeature_RNA", "nCount_RNA", "percent.mt"), ncol = 3)
```

```
object[["percent.HB"]] <- PercentageFeatureSet(object, pattern = "^HB")
VlnPlot(object, features = c("nFeature_RNA", "nCount_RNA", "percent.mt", "percent.HB"), ncol = 4)
```



```
plot1 <- FeatureScatter(object, feature1 = "nCount_RNA", feature2 = "percent.mt")
plot2 <- FeatureScatter(object, feature1 = "nCount_RNA", feature2 = "nFeature_RNA")
plot3 <- FeatureScatter(object, feature1 = "nCount_RNA", feature2 = "percent.HB")
plot1+plot2+plot3
```

细胞过滤

#基于基因数量、线粒体占比过滤低质量细胞

```
object <- subset(object, subset = nFeature_RNA >200& nFeature_RNA <2500&  
percent.mt <5)
```


基础分析

03

单细胞转录组数据的主要特征

1. 稀疏性
2. 高维度
3. 大量的噪声
4. 批次效应
5. 细胞类型的异质性
6. 丰富的生物学信息

为什么UMI定量在不同的细胞中不一样

- 生物学方面：

1. 细胞亚型差异

- 技术方面：


1. scRNA数据本质上具有噪声
2. 每个细胞的mRNA含量低
3. 细胞之间的mRNA捕获效率差异
4. 测序深度不一致
5. PCR扩增效率

数据Normalize

由于测序深度的差异，同一基因在不同细胞中的读数可能会有很大的差异。为了消除这种影响，Seurat会对每个细胞的基因表达量进行归一化，使得所有细胞的总读数相同。这通常通过除以每个细胞的总读数并乘以一个标准化因子（如10000）来实现。

```
pbmc <- NormalizeData(pbmc, normalization.method = "LogNormalize", scale.factor = 10000)
```

高变基因



标准化

不同的基因，其表达量的尺度可能会有很大的差异。为了使得所有基因在后续的分析中能够被公平对待，Seurat会对每个基因的表达量进行标准化，使得所有基因的表达量都服从标准正态分布。这通常通过减去平均值并除以标准差来实现。

```
all.genes <- rownames(pbmc)  
pbmc <- ScaleData(pbmc, features = all.genes)
```



高纬度数据所带来的问题

1. 维度灾难
2. 过拟合问题
3. 计算复杂性高
4. 难以可视化


解决方案：在保留信息的同时将维度数量降下来。

降维聚类分析



聚类分析是量化计算特征相似度,将功能相同或密切联系的细胞聚集成类。



PCA分析




AZENTA 安升达
LIFE SCIENCES




非线性降维

常用非线性降维方法：t-SNE和UMAP

Manifold:





t-SNE



AZENTA 安升达
LIFE SCIENCES

工作原理:


1. 计算高维空间中的相似度
2. 计算低维空间中的相似度
3. 最小化高维空间和低维空间的相似度之间的差异




UMAP

工作原理：

1. 构建高维拓扑
2. 构建低维拓扑
3. 高维拓扑向低维拓扑优化映射



Step 1: Compute a graphical representation of the dataset







Step 2 (non-parametric): Learn an embedding that preserves the structure of the graph

降维分析小结

1. 降维方法简化了高维数据，同时保留了生物信号
2. 单细胞数据分析常用方法包括PCA、t-SNE和UMAP
3. PCA分析对数据进行线性转换，以捕捉主要方差，将数据从数千个基因转化为几个主成分
4. 主成分分析可以用于下游分析，如细胞聚类和轨迹分析。
5. t-SNE和UMAP非线性方法主要用于数据可视化，而不用于下游数据分析


聚类分析

1. 构建K近邻图
2. 基于K近邻图进行聚类





使用Louvain方法，节点首先被分配其自己的社区，循环进行如下两步迭代：

1. 一次一个节点地重新分配到它们能最大程度增加模块度的社区
2. 构建一个新的聚合网络，其中的节点是在上一步中形成的社区



Louvain algorithm. The Louvain algorithm starts from a singleton partition in which each node is in its own community (a). The algorithm moves individual nodes from one community to another to find a partition (b). Based on this partition, an aggregate network is created (c). The algorithm then moves individual nodes in the aggregate network (d). These steps are repeated until the quality cannot be increased further.

t-SNE和UMAP可视化




标志基因鉴定

标志基因的鉴定对于理解细胞的身份和功能至关重要。

- 标志基因可以帮助我们识别新的细胞类型，理解细胞的功能状态，以及揭示细胞的发育轨迹。
- 标志基因可以用于细胞的分类和注释，以及单细胞数据的可视化。

cluster	p_val	avg_log2FC	pct.1	pct.2	p_val_adj	GeneName	GeneID
0	3.09537708276161e-29	1.11047289590627	0.984	0.658	7.78673058939511e-25	IL7R	ENSG00000168685
0	1.60733168458135e-21	1.67374415508158	0.747	0.281	4.04340358573286e-17	ANXA1	ENSG00000135046
0	3.87135115935211e-18	1.08012377457782	0.816	0.492	9.73877097646618e-14	KLF6	ENSG00000067082
0	1.71087629590787e-15	1.18672078195382	0.652	0.245	4.30388040998584e-11	DUSP5	ENSG00000138166
0	1.43622814343947e-14	0.890121299341776	0.772	0.376	3.61297551763633e-10	S100A11	ENSG00000163191

标志基因可视化



细胞亚型鉴定

目前细胞类型鉴定主要有两大途径：

- 一是人工注释，通过专业知识根据细胞亚群标志基因来确定；
- 二是软件自动注释，借助已注释数据集或细胞类型标志基因列表进行注释，比如 SingleR 软件，对人和小鼠样本进行细胞类型预测。

细胞亚型映射

#1. singleR

#提取注释到的细胞亚型

```
celltype = data.frame(ClusterID=rownames(pred),  
                      celltype=pred$labels, stringsAsFactors = F)
```

```
head(celltype)
```

#将注释结果添加进meta.data

```
object@meta.data$singleR=celltype[match(object@active.ident,celltype$ClusterID  
), 'celltype' ]
```

#可视化

```
DimPlot(object, reduction = "umap", group.by = "singleR")
```

#2. 人工注释

#查看当前的细胞聚类标签

```
Idents(object)
```

#将聚类标签映射到细胞类型

```
cluster_to_celltype <- c( "0" = "TypeA", "1" = "TypeB", "2" = "TypeC" )
```

#使用Renameldents重新标注细胞


```
seurat <- Renameldents(object, cluster_to_celltype)
```

```
Idents(object)
```

#可视化

```
DimPlot(object, reduction = "umap", label = TRUE) + NoLegend()
```


细胞亚型可视化




分析拓展

04

为什么需要整合分析

单细胞测序数据集样本间的整合，比如跨实验批次、实验条件等，是分析工作流程中的重要步骤。整合分析可以帮助匹配数据集之间共享细胞类型和状态，可以提高统计能力及跨数据集进行准确的比较分析。



整合分析方法

CCA (Canonical Correlation Analysis, 典型相关分析) 方法是一种常用的技术，尤其在 Seurat 软件包中得到了广泛应用。该方法通过找到两个数据集之间的典型变量（即线性组合），使得这两个变量之间的相关性最大化。

CCA 方法是一种有效的单细胞数据整合技术，可以校正批次效应、整合跨平台数据和单细胞多组学数据等。对于较大的数据集，可能耗时较长且占用较大的内存资源。此外，当数据集之间存在较大差异时，可能无法找到足够的锚点细胞来进行有效的数据整合。

整合分析目的

实现以下分析目标：

- 识别在两个数据集中存在的细胞亚群
- 获得在对照细胞和受刺激细胞中都保守的细胞类型标志物
- 比较数据集，找出对刺激的细胞类型特异性基因

#选择特征基因

```
features <- SelectIntegrationFeatures(object.list = scelist)
```

#查找锚点

```
immune.anchors <- FindIntegrationAnchors(object.list = scelist, anchor.features =  
features, reduction = "cca")
```

#数据整合

```
object <- IntegrateData(anchorset = immune.anchors)
```

```
DefaultAssay(object) <- "integrated"
```


下游分析

#高变基因

```
object <- FindVariableFeatures(object, selection.method = "vst" )
```

#数据标准化

```
object <- ScaleData(object, verbose = FALSE)
```

#降维及聚类

```
object <- RunPCA(object, features = VariableFeatures(object = object))
```


```
object <- FindNeighbors(object, reduction = "pca" , dims = 1:15)
```

```
object <- FindClusters(object, resolution = res)
```

```
object <- RunTSNE(object, reduction = "pca", dims = 1:15)
```

```
object <- RunUMAP(object, reduction = "pca", dims = 1:15)
```

细胞亚群可视化




标志基因

如果在执行完聚类后，一个基因在多个样本的cluster A中都被判断或否定为marker基因，每个样本的结果都具有一定的权重。我们通过加权平均得到最后结论，来判断该基因到底是不是标志基因，比起单样本分析，我们可以更加放心地认同这个结论。并且，我们把通过联合分析得到的标志基因特称为 conserved cell type markers，即它作为标志基因的性质在不同的样本中“守恒”。

```
markers <- FindConservedMarkers(immune.combined, ident.1 = 0, grouping.var = "orig.ident", verbose = FALSE)
```


Thank you!



AZENTA 安升达
LIFE SCIENCES

