




AZENTA 安升达
LIFE SCIENCES

基因富集分析介绍

Chunmei.Tao

2024/7

分析内容展示——单细胞转录组



10X Genomics单细胞转录组数据分析流程

目录

01 富集分析简介

02 数据库介绍

03 富集方法介绍

04 在线富集工具分享

05 富集结果解读

富集分析简介

01



为什么要做富集分析

- 组学数据得到的差异基因或者物质非常多，面对海量数据我们无法做到挨个研究、逐一验证来把待研究现象的机制解析清楚。通过富集分析我们可以把差异基因或者物质根据其功能进行归类，这样具有相似功能的基因或者物质就被放在一起，从而减少工作量。
- 一个生物过程通常不是由单个基因独自完成的，而是由一组基因共同参与。基因富集分析正是基于这一原理，通过分析一组基因在某个功能节点上的表现，来揭示这一生物过程的内在机制。实现功能和表型相关联。





什么是富集分析

• 富集分析 (Enrichment Analysis) 是一种常用的生物信息学方法，用于识别在一个基因集（一组基因、蛋白质或其他生物分子中）中，哪些特定功能或者生物过程比预期更为显著地富集。这种分析通常用于理解实验数据中显著变化的基因或蛋白质列表背后的生物学意义。

• 定义

- **基因集**：某个生物学背景下相关的基因。比如处理条件下的差异基因，参与同一生物过程的基因等。
- **背景集**：背景集通常指在整个实验中测量的所有基因或蛋白质。富集分析将关注的基因集与背景集中基因的分布进行比较。



富集分析步骤



- 兴趣基因列表（如差异基因）
- 背景基因集（如所有的基因）

- ★ • 预定义基因集（如GO、KEGG等数据库中的基因集）

- ★ • 选择统计检验方法（超几何分布检验，GSEA等）

- 计算基因集的富集显著性
- 多重检验校正，控制假阳性率

- ★ • 结合生物学背景和实验设计，解释这些基因集的生物学意义

- 鉴定显著富集的基因集

数据库介绍

02

GO数据库介绍

GO数据库（<https://geneontology.org/>），全称为基因本体论数据库（Gene Ontology Database），是一个描述基因和基因产品属性的国际标准化数据库。它包括三个主要的本体论：生物过程（Biological Process），分子功能（Molecular Function）和细胞组分（Cellular Component）。

- 1.生物过程（Biological Process）：描述了基因或基因产品参与的生物活动。例如，细胞周期、免疫反应等。
- 2. 分子功能（Molecular Function）：描述了基因产品在分子层面上的活动。例如，蛋白质激酶活性、运输等。
- 3. 细胞组分（Cellular Component）：描述了基因产品在细胞中的位置。例如，细胞核、线粒体、细胞膜等。

GO数据库介绍

Tcytochrome c

本品为生物氧化过程中的电子传递体。
其作用原理为在酶存在的情况下，对组织的氧化、还原有迅速的促酶作用。

Molecular Function


氧化还原酶活性

Cellular Component

线粒体膜间隙

Biological Process


氧化磷酸化



GO terms基本要素



GO terms(GO classes)由唯一标识符、名字、定义和一些其他元素组成。

- 唯一标识符和term 名字: GO:0005739 (mitochondrion transport) ,
- 定义 (Definition) : term 内容的文本描述, 以及引用
- 类别 (Aspect) : 表示属于三个子本体论中的哪一个 (cellular component, biological process, molecular function)
- 与其他term的关系: 所有的term (除了三个类的根术语) 都属于另外一个term。





GO Graph

- 每个节点代表一个GO term
- 线代表节点之间的关系
- 父节点更靠近根节点，含义更广泛；子节点更靠近叶节点，含义更细致。



GO Graph



KEGG Pathway 数据库介绍

- KEGG (Kyoto Encyclopedia of Genes and Genomes, <https://www.genome.jp/kegg/>) 是一个综合性的数据库，用于理解高级功能和生物系统的效用，从分子层面到生态层面。它将大量的分子层面的信息整合在一起，包括基因，蛋白质，RNA，化合物，反应和反应路径。

KEGG

Databases

Tools

Auto annotation

Kan



KEGG

KEGG Home

Release notes

Current statistics

KEGG Database

KEGG overview

KEGG mapping

Color codes

KEGG Objects

KEGG Weblinks

Entry format

KEGG Software

KEGG API

KGML

KEGG FTP

Subscription

Background info

GenomeNet

DBGET/LinkDB

KEGG: Kyoto Encyclopedia of Genes and Genomes

KEGG is a database resource for understanding high-level function the biological system, such as the cell, the organism and the ecosystem. It provides molecular-level information, especially large-scale molecular data, genome sequencing and other high-throughput experimental techniques. See [Release notes](#) (May 1, 2024) for new and updated features.

New feature: [Genome alignment](#) (gene order alignment) tool is released.

● Main entry point to the KEGG web service


[KEGG2](#) [KEGG Table of Contents](#) [\[Update notes\]](#)

● Data-oriented entry points


KEGG PATHWAY	KEGG pathway maps
KEGG BRITE	BRITE hierarchies and tables
KEGG MODULE	KEGG modules
KEGG ORTHOLOGY	KO functional orthologs
KEGG GENES	Genes and proteins [Annotation]
KEGG GENOME	Genomes [KEGG Virus Syntax]
KEGG COMPOUND	Small molecules
KEGG GLYCAN	Glycans
KEGG REACTION	Biochemical reactions [RModule]
KEGG ENZYME	Enzyme nomenclature

KEGG Pathway 数据库介绍

•KEGG pathway是KEGG数据库的一个重要部分一个包含了大量代谢途径、生物通路和分子网络的数据库，它为研究人员提供了一个系统的工具来理解和探索生物系统的复杂性和多样性。



Pathway元素

Entry	ksa04930		
Name	Type II diabetes mellitus - Homo sapiens (human)		
Description	Insulin resistance is strongly associated with type II diabetes. etc.		
Class	Human Diseases; Endocrine and metabolic disease		
Pathway map			
Gene	3630 INS; insulin [KO:K04526] 3643 INSR; insulin receptor [KO:K04527] [EC:2.7.10.1]		
Compound	C00002 ATP C00022 Pyruvate		
Reference	PMID:15823385		
Authors	Stumvoll M, Goldstein BJ, van Haeften TW.		
Titile	Type 2 diabetes: principles of pathogenesis and therapy.		
Journal	Lancet 365:1333-46 (2005) DOI:10.1016/S0140-6736(05)61032-X		



Pathway标识符

- 每个pathway图都有一个名字，由2-4个字符的前缀，和5个数字组成（hsa04930）。
- 前缀：只是通路类型或物种信息
 - Map：代表手工绘制的参考通路图
 - ko：表示不同物种间保守的直系同源基因和基因产物
 - ec：代表酶的国际公认识别编号（EC numbers），用于分类和标识酶催化的反应。
 - Rn：反应的参考代谢途径
 - <org>：特定的物种或者生物体。比如hsa代表人。




Pathway类别

- 代谢途径 (Metabolism) : 这些途径描述了各种生物分子的生物合成和降解过程, 如碳水化合物代谢、脂质代谢、氨基酸代谢等。
- 遗传信息处理 (Genetic Information Processing) : 这些途径涵盖了DNA复制、转录、翻译等过程。
- 环境信息处理 (Environmental Information Processing) : 涉及生物体如何感知和响应外部环境变化。这些途径主要描述了信号转导途径, 如G蛋白偶联受体信号途径、MAPK信号途径等。
- 细胞过程 (Cellular Processes) : 涉及细胞的各种功能和复杂的信号传导网络。涵盖了细胞周期、凋亡、自噬等过程。
- 有机系统 (Organismal Systems) : 这些途径描述了在器官或生物体层面上的过程, 如免疫系统、神经系统等。
- 人类疾病 (Human Diseases) : 这些途径描述了与特定疾病相关的分子和途径, 如癌症、神经退行性疾病等。有助于疾病的研究和治疗。
- 药物开发 (Drug Development) : 涉及药物作用机制和药物代谢的通路。此类别提供了药物开发过程中所需的通路信息, 有助于药物的设计和筛选。




Pathway map




Enzyme-enzyme relations




Gene expression relations




Protein-protein interactions



Objects



Arrows



Red coloring in disease pathway maps





Reactome数据库介绍


- Reactome (<https://reactome.org/>) 是一个免费、开源、经过整理和同行评审的通路数据库。它的目标是提供直观的生物信息学工具，用于通路知识的可视化、解释和分析，以支持基础研究、基因组分析、建模、系统生物学和教育。

Reactome介绍

Reactome数据模型的核心是reaction。

参与reaction的实体（核酸、蛋白质、复合物、疫苗、抗癌疗法和小分子）形成生物互作网络。

一个Reactome pathway 类似于一个科学综述，由专家和Reactome编辑人员合作编写，确保所有结果都有原始文献的支持。



Reactome介绍

Reactome涵盖了15个物种的通路研究，包括七个哺乳动物以及一些常见的模式生物。

Reactome包括15212种人类反应，这些反应被组织成2698种途径，涉及30585种蛋白质和由11226种不同人类基因编码的修饰形式的蛋白质，14789种复合物，2128种小分子和1047种药物。（V88）

Species	Proteins	Isoforms	Complexes	Reactions	Pathways
<i>Mus musculus</i>	9,723	29	11,147	9,950	1,748
<i>Rattus norvegicus</i>	8,967	10	9,851	8,637	1,735
<i>Homo sapiens</i>	11,226	216	14,777	15,212	2,698
<i>Sus scrofa</i>	8,851	0	9,304	8,094	1,719
<i>Bos taurus</i>	8,971	0	9,495	8,319	1,728
<i>Canis familiaris</i>	8,338	0	9,141	7,835	1,700
<i>Gallus gallus</i>	7,409	2	8,247	7,070	1,747
<i>Xenopus tropicalis</i>	5,512	0	5,943	5,092	1,511
<i>Danio rerio</i>	4,312	0	4,532	3,956	1,360
<i>Caenorhabditis elegans</i>	4,444	0	4,721	3,960	1,359
<i>Drosophila melanogaster</i>	4,873	2	5,841	4,959	1,520
<i>Schizosaccharomyces pombe</i>	1,873	0	2,183	1,673	869
<i>Saccharomyces cerevisiae</i>	2,039	0	2,118	1,757	856
<i>Dictyostelium discoideum</i>	2,859	0	2,822	2,426	1,030
<i>Plasmodium falciparum</i>	1,223	0	1,268	1,005	638

Reactome和KEGG Pathway的异同



免费，开源	定位	部分内容仅对学术用户免费
专注于生物分子通路	内容	多个类别的通路和分子相互作用网络
NCBI Gene、Ensembl、UniProt等数据库；PubMed文献等；有相关人员进行核验	数据来源	人工绘制，文献，数据库， 用户贡献等
查询，浏览，注释，富集分析等	应用和工具	查询，浏览，注释（限定）

GO、Pathway富集分析的区别是什么？

GO是用来找基因引起的功能改变，用于解析基因或蛋白质在特定生物学条件下的功能特性。

Pathway是用于寻找代谢途径、信号转导、细胞周期等生物学过程中的影响。为揭示生物学过程的复杂性和系统性提供有力支持。



MSigDB数据库介绍



MSigDB, 全称Molecular Signatures Database (分子特征数据库), 是一个基因集数据库, 包含多种功能注释的基因集, 是一个开放资源平台。

<https://www.gsea-msigdb.org/gsea/msigdb/index.jsp>

Human Collections	
H hallmark gene sets are coherently expressed signatures derived by aggregating many MSigDB gene sets to represent well-defined biological states or processes.	C5 ontology gene sets consist of genes annotated by the same ontology term.
C1 positional gene sets corresponding to human chromosome cytogenetic bands.	C6 oncogenic signature gene sets defined directly from microarray gene expression data from cancer gene perturbations.
C2 curated gene sets from online pathway databases, publications in PubMed, and knowledge of domain experts.	C7 immunologic signature gene sets represent cell states and perturbations within the immune system.
C3 regulatory target gene sets based on gene target predictions for microRNA seed sequences and predicted transcription factor binding sites.	C8 cell type signature gene sets curated from cluster markers identified in single-cell sequencing studies of human tissue.
C4 computational gene sets defined by mining large collections of cancer-oriented expression data.	

Mouse Collections	
MH mouse-ortholog hallmark gene sets are versions of gene sets in the MSigDB Hallmarks collection mapped to their mouse orthologs.	M3 regulatory target gene sets based on gene target predictions for microRNA seed sequences and predicted transcription factor binding sites.
M1 positional gene sets corresponding to mouse chromosome cytogenetic bands.	M5 ontology gene sets consist of genes annotated by the same ontology term.
M2 curated gene sets from online pathway databases, publications in PubMed, and knowledge of domain experts.	M8 cell type signature gene sets curated from cluster markers identified in single-cell sequencing studies of mouse tissue.

富集方法介绍

03

富集分析方法类型



超几何分布检验 (Hypergeometric Test)



基因集变异分析 (GSVA, Gene Set Variation Analysis)



其他，如GSEA等

超几何分布检验

最常用富集分析方法之一。它计算在背景集和目标基因集已知的情况下，特定基因集在目标基因集中出现的概率。

主要用于GO (Gene Ontology) 富集分析，KEGG (Kyoto Encyclopedia of Genes and Genomes) pathway分析等。

总共有N个球，其中M个是白球，不放回的抽n次，抽到k个以上白球的概率。

1. 超几何分布

总共有N个球，其中M个是白球，不放回的抽n次，抽到k个白球的概率分布符合超几何分布。

$$P(X = k) = \frac{C(M, k) \times C(N - M, n - k)}{C(N, n)}$$

2. 计算P 值

我们通常关心的是观察到的成功次数是否显著大于随机抽取的预期值，这时就需要计算P值。超几何分布的P值计算公式通常用于计算观察到至少m次成功的概率。

总共有N个球，其中M个是白球，不放回的抽n次，抽到m个白球

$$p = 1 - \sum_{i=0}^{m-1} \frac{\binom{M}{i} \binom{N-M}{n-i}}{\binom{N}{n}}$$

3. 多重假设检验

P值容易出现假阳性，需要利用多重假设检验对P值进行矫正。可以使用Bonferroni法和FDR法。一般使用0.05作为判断条件是否是显著富集的阈值。

基因集变异分析 (GSVA, Gene Set Variation Analysis)



GSVA (Gene Set Variation Analysis) 是一种用于基因集富集分析的方法。GSVA不依赖于预先定义的表型分类，而是直接对样本中的基因表达数据进行分析，从而评估基因集在不同样本中的活性变化。

原理与特点

无监督分析：GSVA不需要预先定义的表型标签，因此适用于探索性数据分析，可以揭示潜在的生物学信号。

样本水平的富集评分：GSVA通过将基因表达数据转换为样本层面的富集评分，从而在单个样本层面评估基因集的活性。

连续评分：GSVA为每个基因集在每个样本中提供一个连续评分，这些评分反映了基因集在样本中的相对活性。

处理噪音和数据偏差：通过对基因表达矩阵进行核密度估计，GSVA能有效处理表达数据中的噪音和偏差。

基因集变异分析 (GSVA, Gene Set Variation Analysis)

--步骤



基因表达矩阵：输入的是一个基因表达矩阵，行表示基因，列表示样本。

基因集定义：基因集通常从数据库（如MSigDB）获取，表示特定生物过程或通路。


核密度估计：对每个基因在每个样本中的表达值进行核密度估计，转换为表达概率分布。

富集评分计算：通过比较基因集中的基因表达概率分布与全基因集的背景分布，计算出每个样本中基因集的富集评分。

结果输出：生成一个评分矩阵，其中每一行为基因集，每一列为样本。

Geneset	0	1	2	3	4
HALLMARK_APOPTOSIS	-0.495	-0.567	0.101	-0.075	0.008
HALLMARK_NOTCH_SIGNALING	-0.538	-0.522	0.187	0.164	0.194
HALLMARK_ADIPOGENESIS	-0.167	-0.379	-0.163	-0.207	-0.013

GSVA结果展示



GSVA的优势

适用于复杂数据：GSVA可以处理高噪音和异质性的基因表达数据。

灵活性高：不依赖预先定义的表型标签，适用于各种探索性研究。

连续变量分析：提供连续的评分，便于进一步的统计分析和可视化。

GSVA的局限性

计算复杂度：由于涉及核密度估计，计算量较大，尤其在大规模数据集上。

依赖于基因集定义：结果依赖于输入的基因集质量和定义的准确性。

总的来说，GSVA是一种强大的工具，在基因表达数据的富集分析中提供了无监督的、连续评分的分析方法，适用于多种生物学研究。

在线富集工具演示

04

<https://metascape.org/gp/index.html#/main/step1>，使用简单，好看

<https://maayanlab.cloud/Enrichr/>，分析全面，输入ID种类少

<https://david.ncifcrf.gov/>，更新慢，可以进行ID转换

<http://kobas.cbi.pku.edu.cn/>，不支持gene symbol

富集结果解读




05

富集分析结果展示

category	term	ontology	numDEinC at	numInCat	over_repre sented_pv alue	over_repre sented_FD R	GeneNumb er(Up)	GeneNumb er(Down)
GO : 0005615	extracellula r space	CC	124	1056	3.15e-40	4.28e-36	100	24

PathwayID	Pathway	Level1	Level2	DEGs with pathway annotation	All genes with pathway annotaion	Pvalue	Qvalue	GeneNumbe r(Up)	GeneNumbe r(Down)
ko04750	Inflammatory mediator regulation of TRP channels	Organis mal Systems	Sensory system	9(2.15%)	81(0.94%)	1.15e-03	1.15e-03	7	2

富集分析结果展示



MSU crystal deposition contributes to inflammation and immune responses in gout remission

[Hongchen Gu](#) ³ • [Hanqing Yu](#) ³ • [Ling Qin](#) ³ • ... [Zisheng Ai](#) • [Bei Xu](#)   • [Ai Peng](#)  ⁴  •



[Show all authors](#) • [Show footnotes](#)

Open Access • Published: September 26, 2023 • DOI: <https://doi.org/10.1016/j.celrep.2023.113139> •




 Check for updates





[发表期刊]	Cell Reports
[影响因子]	8.8
[发表时间]	2023.09
[发表单位]	上海市第十人民医院



案例分享




案例分享



差异富集

GSVA

Thank you!



AZENTA 安升达
LIFE SCIENCES