




AZENTA 安升达
LIFE SCIENCES

Monocle2 基础培训

黄鑫鹏

2024年/07月/12日

目录




Monocle2 介绍	01
分析思路	02
结果解读	03
注意事项	04
代码示例	05

Monocle2 介绍

01

照片顺序复原挑战

- 想象有**几位摄影师**从一个知名景点的入口 **R 点**出发，沿途**高频率拍摄**这个地区的风景，并约好汇总拍摄成果，按照沿途路线轨迹做一个照片集
- 有的摄影师走到 **A 点**后，觉得 **3号分路线**的风景很吸引人，便与其他人分头行动，有的摄影师从 **B 点**与大部队分开，沿途大家拍摄了很多漂亮的照片
- 拍摄结束后，大家把洗好的照片按照约定的顺序交给了张三来制作照片集
- 张三骑车回工作室的途中，装照片的袋子破损了，**照片尽数散落在地上.....**
- 张三拾起照片后，发现照片的顺序完全打乱了，**如何尽可能复原？**



照片顺序复原挑战

复原照片集路线轨迹的线索

一个基本假设：拍摄时间和地点相近的照片，风景应该会比较接近的。


照片包含以下信息：

- 拍摄对象（园林，飞鸟，水塘，落叶等众多物体）× 数目
- 风格类：构图、色调、镜头焦距、光照变化.....

复原顺序的一个思路：

1. 先筛选出照片中最具备识别度的一类特征（人眼自带的功能，**特征筛选**），然后根据特征的相似性对照片进行排列，摆布在一张方桌的不同位置（**降维**）。
2. 从照片排布中尝试用肉眼拟合出主要的趋势线（格式塔心理学），然后将照片摆放到趋势线附近。继续拟合新的趋势线，再调整照片位置.....直到不需要再移动。
3. 判断趋势线的方向，根据先验知识找到入口处R（例如我们可以通过地图软件查询到**景区入口R点**的样子）

通过上述思路，张三将真实情况基本还原了出来，还原度近70%.....



单细胞拟时序分析

单细胞拟时序分析，又称细胞轨迹（cell trajectory）分析，单细胞伪时间（pseudotime）轨迹分析等，它可以通过构建细胞间的变化轨迹来重塑细胞随着时间的变化过程。

单细胞拟时序分析的生物学原理：

- 在许多生物学程中，单个细胞以不同步的方式执行基因表达过程
- 我们在实验时捕获的细胞在分化方面的分布可能比较广泛。在同一时间捕获的细胞群中，**有些细胞可能已经分化很长过时间了，而有些细胞甚至还没有开始这个过程**
- 因此每个细胞都是我们要研究的转录过程的一个瞬间（类比为照片）

单细胞拟时序分析


拟时序(伪时间)的本质是对细胞进行排序，排序需要有确定的规则。

每个细胞都有与成千上万个基因表达，而每个基因的表达量都可以单独作为一种排序规则，我们需要通过一步步**删繁就简**，在**低维空间**上理解**高维空间**中**细胞间状态的差异**。

1. 特征提取（筛选基因，发育相关 or 信息量大）>>> 维数从成千上万到 <3000
2. 降维（例如PCA, 提取特征基因中最重要的信息）>>> 维数从<3000 到 ~50
3. PCA基础上二次降维 >>> Monocle2 使用 DDRtree, 维数从 ~50 到 2-3
4. 定义先后顺序，软件预测或手动指定起始点（Root）

拟时序分析中，伪时间是一个抽象的细胞分化单位，它指的是一个细胞沿着细胞轨迹到起始点（Root）的距离。

Monocle2核心算法思想




1. 每个细胞可以表示为高维空间中的一个点，其中每个维度对应一个基因的表达水平排序；

2. 将高维数据通过PCA(默认)降维方法投射到低维空间 (Z) ；

3. Monocle 2 通过算法在低维空间中选择一组点作为数据中心点，并在此基础上串联各中心点，构建一棵生成树。


Monocle2核心算法思想



4. 将细胞移动到最接近的生成树的中心点，然后更新中心点位置以拟合新的细胞位置，学习新的生成树，并反复进行此过程，直到树和细胞位置收敛。

每次更新细胞位置并细化树时，轨迹的结构会一步步简化，修剪掉小的分支，这样**最终的轨迹只保留了描述细胞状态显著差异的分支。**

Monocle2核心算法思想



5. 在上述计算过程中，Monocle2 会维持高维空间和低维空间之间的可逆映射，从而既学习了轨迹，又降低了数据的维数。

6. Monocle2 学习到树的结构后，可以选择一个末端作为根节点（Root）。每个细胞的伪时间计算为沿树到根的测地距离（沿着生成树的路径距离），并根据低维空间的主干图自动分配分支。

Monocle2的应用场景

Monocle2可以做什么：

- 降维聚类，细胞质控，辅助细胞注释（Seurat, Scanpy 等上游分析包含）
- 构建细胞分化轨迹 *
 - 细胞分化关系研究
 - 细胞分化相关基因研究
- 差异表达分析（Seurat, Scanpy 等上游分析包含）
-

分析思路

02

Monocle2 分析前数据处理

输入数据：以 Seurat v4 为例，Monocle2 分析的输入数据通常是至少完成大类细胞注释的rds格式，细胞的细分注释尽可能细致但非必需，缺乏细分注释的先验知识时，可以考虑使用无监督聚类的 Cluster 编号代替。

1. 筛选要进行拟时序分析的细胞类型

基于已有的生物学知识，排除与研究无关的细胞类型。例如，想要研究T细胞在某种条件下的分化轨迹，可以剔除掉上皮细胞，成纤维细胞等与T细胞明确没有分化关系的细胞

2. (可选) 降采样，加速探索性分析效率

Monocle2 可分析的细胞数上限约在4~5万, 非常耗费计算资源，超出细胞数限制则无法正常生成结果，如果细胞数太多，可以选择每种细胞类型最高采样N个细胞（例如 N=1000）

3. 将 seurat object 转成 monocle2 支持的数据格式

Monocle2 分析

1. (可选) 数据质控

(已在Seurat等上游分析软件中质控过) 过滤低质量细胞, 过滤低表达基因

2. 估计尺寸因子和分散度

size factor 影响数据标准化, dispersion 影响差异分析

3. 选择定义细胞过程的基因 (特征选择, 下面方法四选一)

- 有发育关系的细胞类型间的差异表达基因 (推荐)
- 无监督聚类的Clusters差异表达基因
- 选择离散程度高的基因 (Seurat或Monocle2计算的高可变基因)
- 自定义发育marker基因 (使用先验知识辅助分析)

Monocle2 分析

4. 降维

使用Monocle2推荐的反向图嵌入(DDRTree)算法对数据进行降维

5. 细胞拟时序轨迹构建，可视化

根据 step.3 中定义的基因的表达趋势，将细胞进行排序并完成轨迹构建，同时会自动定义Root位置。

6. (可选) 重新指定伪时间轴的起点 (Root) 位置

如果 step.5 定义的Root位置与生物学知识不符，可以手动指定Root位置

Monocle2 分析

7. (可选) 伪时间基因表达分析建模

寻找伪时间相关基因，热图可视化，基因表达模式聚类。Monocle2可以通过分析生物过程（如细胞分化）将细胞按顺序排列，然后可以分析细胞，找到随着细胞进展而变化的基因。

8. 分支表达分析建模 (Branched expression analysis modeling, BEAM)

寻找分支相关的基因（哪些基因影响了细胞命运选择），热图可视化，基因表达模式聚类。在发育过程中，当细胞做出命运选择时，就会出现分支：一个发育谱系沿着一条路径前进，而另一个谱系产生第二条路径。


9. (可选) 指定基因的可视化

结果解读

03

细胞轨迹分支图

1. 先找 **Root** 的位置，查看按照 **Pseudotime** 上色的细胞轨迹图，**Pseudotime = 0** 的位置为Root；
2. 再找 **Branch** 的位置，右图中A,B对应的分叉点即为 Branch（在 Monocle2 中实际也是按照数字编号的）；
3. 分叉点和轨迹起点/终点之间，或者分叉点和分叉点之间为一个 State（State编号与发育轨迹时间先后没有关系）






细胞轨迹分支图

4. 细胞谱系按照 Pseudotime 从小到大的顺序进行生物过程


5. Branch 暗示细胞在这个阶段可能面临命运选择（分化），每个 Branch 点由三个 State 组成。

- 从 Root 到 Branch 线段对应的 State 被定义为 **Pre-branch**（例如右图 Branch B 的 Pre-branch 为 State 1 和 State 2）。
- Branch 另外2个 State 代表 Pre-branch 的两种细胞命运 **Cell fate 1**（编号小的State） 和 **Cell fate 2**（编号大的State）。

State 1 2 3



伪时间依赖性基因热图




可视化目标: 展示随着细胞过程进展而显著变化的 TOP N 基因，并根据表达模式聚类。（伪时间依赖性基因）

思路: 将轨迹构建基因（排序基因）的表达量信息与伪时间进行拟合，使用回归分析以确定各基因表达量与伪时间之间的显著关系。之后可以选择 qval top N 差异基因进行热图可视化，并选择将其根据表达模式的相似性聚类成 K 个簇。

图解: 横坐标从左到右对应伪时间从小到大的方向。纵坐标对应qval Top N基因（N=100），中间是每个基因的表达量随着伪时间的变化情况。左边的cluster对应基因按照人工选择的聚类簇数目（K=4）聚类而成的几种基因表达模式，在K值选择合理的情况下，每个簇内的基因遵循相似的动力学趋势。

分支依赖性基因热图



BEAM(Branched expression analysis modeling)是 Monocle2 中的一种统计方法，用于寻找以依赖于分支的方式调控的基因。我们可以选择要分析的分支点 id 进行BEAM 分析，之后可以选择 qval top N 差异基因进行热图可视化，并决定将其聚类成 K 种表达模式。

图解：横坐标以中间为伪时间起点，中到左和中到右分别对应两种细胞分化命运中伪时间从小到大的方向。纵坐标对应 qval Top N基因（N=100），中间是每个基因的表达量随着伪时间的变化情况。左边的cluster对应基因按照人工选择的聚类簇数目（K=4）聚类而成的几种基因表达模式，在K值选择合理的情况下，每个簇内的基因遵循相似的动力学趋势。


注意事项

04

注意事项

1. Monocle2 的连通性很强，可能将没有生物学相关性的细胞进行轨迹串联，造成假阳性结果。
 - 需要根据生物学知识尽可能排除不相关细胞类型，再进行分析
 - 检查轨迹中细胞分布的均匀性，如果细胞轨迹有较大的不连续区段，可能暗示结果不可靠。
2. Monocle2构建的细胞轨迹图不一定很完美，只要主体趋势的分析结果是可靠的即可。
3. Monocle2 构建好细胞轨迹后，可能错误指定起点（Root）位置，需要根据生物学知识，进行调整。
4. Monocle2 可分析的细胞数上限在4-5万，超出细胞数限制无法正常生成结果，必须进行降采样。

Thank you!



AZENTA 安升达
LIFE SCIENCES